



貴州大學

本科毕业论文（设计）

论文（设计）题目：

基于深度学习的光伏板表面缺陷识别算法研究

学 院： 计算机科学与技术学院（贵州保密学院）

专 业： 计算机科学与技术

班 级： 计科 2103

学 号： 2100170271

学生姓名： 习 驰

2025 年 5 月 30 日

贵州大学本科毕业论文（设计）

诚信责任书

本人郑重声明：本人所呈交的毕业论文（设计），是在导师的指导下独立进行研究所完成。毕业论文（设计）中凡引用他人已经发表或未发表的成果、数据、观点等，均已明确注明出处。

特此声明。

论文（设计）作者签名：习 驰

日 期：2025.5.30



目录

摘要	III
Abstract.....	IV
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
1.2.1 传统目标检测算法	1
1.2.2 基于深度学习的目标检测算法	2
1.2.3 YOLO 系列算法	4
第二章 相关理论与技术基础	6
2.1 卷积神经网络基础	6
2.1.1 网络架构与特征提取机制	6
2.1.2 目标检测中的多尺度特征融合	7
2.2 YOLOv8 算法原理	9
2.2.1 网络结构	9
2.2.2 无锚框设计	10
2.2.3 损失函数设计	11
2.3 模型评价指标与工业检测需求	12
2.3.1 通用检测评价指标	12
2.3.2 光伏板缺陷检测的特殊性要求	14
第三章 基于 YOLOv8 光伏板缺陷检测算法	15
3.1 光伏板缺陷数据集构建	15
3.1.1 数据集的预处理	15
3.1.2 数据分布特性分析	15
3.2 基于 YOLOv8 的模型优化	17
3.2.1 实验环境	17
3.2.2 动态学习率策略与优化器	17



3.2.3 正则化技术应用	17
3.2.4 增量训练策略	18
3.2.5 注意力机制	20
3.3 关键问题与解决方案	21
3.3.1 图像增强策略	21
3.3.2 分类损失震荡优化策略	21
3.3.3 小目标检测增强策略	22
3.4 实验结果分析	23
3.4.1 PR 曲线	23
3.4.2 F1 分数	24
3.4.3 混淆矩阵及其归一化	25
第四章 光伏板缺陷检测系统设计与实现	27
4.1 检测流程设计	27
4.2 基于 PyQt 的页面搭建	28
4.2.1 PyQt 介绍	28
4.2.2 PyQt 功能模块实现	28
4.3 检测结果可视化方案	29
第五章 总结与展望	33
5.1 研究总结	33
5.2 未来改进方向	33
参考文献	35
致谢	37



基于深度学习的光伏板表面缺陷识别算法研究

摘要

针对光伏板表面缺陷人工检测效率低、传统算法泛化性差的问题，本文提出基于 YOLOv8 改进的光伏板缺陷检测算法与可视化系统。首先，构建了包含划痕、断栅与脏污三类缺陷的光伏板图像数据集，为算法训练提供数据支撑；其次，在模型训练过程中，将动态学习率策略和正则化技术相结合，采用增量训练方法，有效突破了小目标检测的瓶颈；此外，通过引入多尺度特征融合机制和动态数据增强策略，在测试集上的 mAP50 检测准确率达到 94.3%。并且单幅图像推理时间在 4.5ms 以内，断栅类缺陷的召回率比原始水平提高了 7 个百分点，达到 93.7%。最后，开发了基于 PyQt 框架的可视化检测系统，集成双模式检测、实时标注、数据追溯等功能，支持 CSV 格式报告导出，为光伏电站智能化运维提供了可落地的技术方案。实验表明，本文在检测精度、实时性与工程实用性方面较现有方法具有显著优势。

关键词： 目标检测，深度学习，缺陷识别，数据增强，PyQt 检测系统



Research on Deep Learning based Surface Defect Recognition Algorithm for Photovoltaic Panels

Abstract

In response to the low efficiency of manual detection of surface defects in photovoltaic panels and the poor generalization of traditional algorithms, this study proposes an improved photovoltaic panel defect detection algorithm and visualization system based on YOLOv8. Firstly, a photovoltaic panel image dataset containing three types of defects: cracks, broken grids, and spots was constructed to provide data support for algorithm training; Secondly, during the model training process, dynamic learning rate strategies and regularization techniques are integrated, and an incremental training method is adopted to effectively break through the bottleneck of small object detection; In addition, by introducing a multi-scale feature fusion mechanism and dynamic data augmentation strategy, a detection precision of 94.3% for mAP50 was achieved on the test set. The single image inference time was within 4.5ms, and the recall rate of broken grids defects increased by 7 percentage points to 93.7% compared to the original level. Finally, a visual detection system based on the PyQt framework was developed, integrating dual-mode detection, real-time annotation, data tracing, and other functions. It supports CSV format report export and provides a practical technical solution for intelligent operation and maintenance of photovoltaic power plants. The experiment shows that this study has significant advantages over existing methods in terms of detection accuracy, real-time performance, and engineering practicality.

Keywords: Object detection, deep learning, defect recognition, data augmentation, PyQt detection system



第一章 绪论

1.1 研究背景与意义

在全球生态问题日益严峻的背景下，可再生能源的发展已成为破解能源与环境矛盾的关键路径。光伏发电技术凭借其清洁性、可持续性及技术成熟度，成为可再生能源领域最具潜力的解决方案之一。与传统化石能源相比，光伏发电不仅能够从源头实现零碳排放，且系统运行无噪音、无污染物排放，兼具环境友好性与能源高效性^[1]。据统计，截至 2024 年年底，国家电网新能源累计并网装机达 11.4 亿千瓦，占全世界的 30% 以上，新能源利用率连续多年保持在 95% 以上^[2]。这一数据充分印证了光伏发电在优化能源结构、降低环境影响方面的核心价值，其为构建清洁低碳的现代能源体系提供了重要技术支撑。

然而，光伏板长期暴露于户外复杂环境，面临灰尘沉积、机械磨损、热应力等多重挑战，极易产生划痕（Crack）、断栅（Grid）、脏污（Spot）等表面缺陷。这些缺陷不仅导致组件发电效率显著下降，更可能引发热斑效应，造成电池局部过热甚至火灾风险，严重威胁光伏电站的安全^[3]。当前行业普遍依赖人工巡检与红外热成像技术进行缺陷检测，但出于对成本和效率等问题的综合考量，传统检测方式难以满足大规模光伏电站的精细化运维需求。

针对上述行业发展瓶颈，本文围绕深度学习与计算机视觉技术的融合创新展开探索，通过设计深度学习算法与可视化识别系统，提出基于 YOLO 目标检测算法的光伏板表面缺陷识别解决方案，有效提升模型在复杂真实场景下的缺陷分类与检测能力。本文致力于为光伏电站运维打造一套低成本、高效率的缺陷检测体系，该方案不仅能够显著降低能源损耗，延长光伏设备使用寿命，提升电站运维效率；同时，其技术思路与方法也为其他工业表面缺陷检测场景提供了可复用的技术范式，助力推动光伏行业与智能制造技术的深度融合与协同发展。

1.2 国内外研究现状

1.2.1 传统目标检测算法

传统目标检测算法的核心流程涵盖区域选择、特征提取与分类决策三个关键环节。在区域选择阶段，滑动窗口技术通过多尺度遍历图像生成候选区域，虽计算成本较高但



覆盖全面，而选择性搜索算法则基于图像超像素的颜色、纹理等信息合并生成候选区域，有效减少了冗余窗口数量。特征提取环节依赖人工设计的特征算子，例如 Haar-like^[4]特征通过矩形模板捕捉图像灰度变化，计算效率高且适用于人脸检测等刚性目标场景；尺度不变特征变换（Scale-Invariant Feature Transform, SIFT）^[5]则通过关键点检测和描述子生成，实现对图像尺度、旋转和光照变化的不变性，适用于复杂场景下的目标匹配。特征提取阶段依赖人工设计的描述符。分类决策阶段常采用支持向量机（Support Vector Machine, SVM）^[6]、决策树^[7]、AdaBoost^[8]等方法对提取的特征进行分类。

2001 年, Paul Viola 和 Michael Jones^[9]提出了面向对象检测的 Viola-Jones 检测模型, 这使实现实时人脸检测成为了可能。2005 年方向梯度直方图（Histograms of Oriented Gradient, HOG）^[10]的出现进一步推动了技术进步, 通过梯度方向直方图统计与块归一化处理, 该特征描述子通过在密集单元网格上的重叠局部进行梯度方向直方图统计与块归一化处理, 显著提升了检测精度, 在行人检测等场景中展现出优异性能。2008 年可变形部件模型（Deformable Part-based Model, DPM）^[11]的问世, 标志着目标检测进入结构化建模阶段, 其通过根滤波器与可变形部件的层次化设计, 采用潜变量支持向量机实现端到端训练, 其灵活的变形模型能够适应物体外观、比例和姿态的变化, 在 PASCAL VOC 等基准数据集上取得显著突破。

从典型算法的原理与性能来看, HOG 结合 SVM 的检测框架在刚性目标检测中表现突出, 但对目标遮挡和非刚性形变的适应性较弱; Haar 特征与级联 Adaboost 分类器的组合实现了实时人脸检测, 但对旋转和多尺度目标的检测精度受限; SIFT 算法虽具备优异的不变性特征, 但高维度特征向量导致计算复杂度较高, 且对边缘光滑目标的特征提取效果不佳。

1.2.2 基于深度学习的目标检测算法

传统目标检测方法主要依赖手工设计特征与机器学习分类器的组合, 虽在早期取得一定成果, 但面临着尺度变化、复杂背景、遮挡和内类差异等挑战, 其在动态场景中的检测精度与鲁棒性显著受限。在 2012 年, Krizhevsky 等人^[12]提出的 AlexNet 通过卷积神经网络（Convolutional Neural Network, CNN）自动学习图像特征, 该模型采用 ReLU 激活函数和局部响应归一化技术, 在 ImageNet 图像分类任务中以 15.32% 的低错误率超越传统方法, 标志着计算机视觉进入深度学习时代。随后在 2014 年, VGGNet^[13]（错误



率 7.32%) 与 GoogLeNet^[14] (错误率 6.66%) 通过增加网络深度与引入多尺度特征融合机制, 其中 VGGNet 采用 3×3 小卷积核堆叠策略, GoogLeNet 引入 Inception 模块减少参数数量, 进一步验证了深度模型对复杂视觉特征的提取能力, 为检测算法的革新奠定了理论基础。

目前, 基于深度学习的目标检测方法可以分为两类, 一类是基于回归的单阶段 (One-Stage) 算法; 另一类是基于区域建议的两阶段 (Two-Stage) 算法^[15]。

两阶段算法以 R-CNN 系列为代表, 将检测任务分解为候选框生成与目标分类回归两个阶段。2014 年 R-CNN 首次将 CNN 引入目标检测, 但每个候选框需独立提取特征, 因此存在重复计算问题^[16]; 同年 SPPNet^[17]提出空间金字塔池化层, 允许不同尺寸候选框共享全图卷积特征, 有效解决了候选框尺寸不一致导致的输入问题, 减少冗余计算; 2015 年 Fast R-CNN^[18]引入 RoI Pooling 实现端到端训练, 通过多任务损失函数将分类与回归统一, 同时优化目标类别预测和边界框坐标回归, 训练速度较 R-CNN 提升 9 倍; 同年 Faster R-CNN^[19]突破性地将候选框生成融入网络, 借助区域建议网络 (Region Proposal Network, RPN) 生成锚框并预测目标位置, 该网络与主干特征提取网络共享卷积计算, 真正实现检测流程的端到端整合, 在 VGG16 模型上达到 5fps 的推理速度; 2017 年 Mask R-CNN^[20]进一步扩展功能, 通过新增掩码预测分支支持实例分割, 并用 RoI Align 层替代传统 RoI Pooling, 通过双线性插值保留更精确的空间位置信息, 优化定位精度, 在 COCO 等数据集上保持领先的检测精度。

单阶段算法以 YOLO (You Only Look Once) 和 SSD (Single Shot MultiBox Detector) 为代表, 致力于在速度与精度间寻求平衡。与两阶段目标检测算法相比, 单阶段算法通过单次前向传播直接预测目标边界框坐标和类别概率, 将目标检测问题转化为端到端的回归任务, 省略了候选框生成的独立计算阶段, 相较于传统两阶段检测方法, 实现了更快的检测速度。就 SSD 而言, 通过在多个卷积层上进行多尺度锚框预测, 结合特征金字塔结构, 在速度 (58fps) 和精度 (mAP 值为 76.8%) 之间取得了较好的平衡^[21]; 2017 年 RetinaNet^[22]提出焦点损失函数 (Focal Loss), 通过为易分类样本分配更低的权重, 抑制简单背景样本对训练的主导作用, 有效解决正负样本失衡问题, 使单阶段算法精度首次超越两阶段模型。

在光伏缺陷检测领域, 早期研究奠定了深度学习的应用基础。2014 年王宪保等人^[23]

首次将卷积神经网络应用于太阳能电池片表面缺陷识别，针对太阳能电池片表面常见的隐裂、断栅、碎片等微小缺陷，提出多尺度特征融合策略，使隐裂、断栅等微小缺陷的检测 mAP 较传统方法提升 12% 以上，推动了深度学习在工业质检中的工程化落地。针对该领域小目标检测难题，涂俊博等人^[24]提出了一种轻量型 YOLOv5 模型，通过 C3TR 模块替代传统 C3 层，利用 Transformer 自注意力机制中的多头注意力结构增强跨尺度特征交互，在减少 18% 参数量的同时提升长程依赖建模能力；引入 SiLU 激活函数优化非线性表达，增强低照度下的特征鲁棒性；嵌入 CBAM 注意力机制动态聚焦缺陷区域，抑制背景噪声，使小目标召回率提升 9.3%；结合 K-means 聚类优化锚框比例，根据光伏缺陷的实际尺寸分布调整锚框先验，减少冗余候选框，推理速度提升 15%。实验表明改进模型在自建光伏数据集上 mAP@0.5 达 95.9%，较基准模型提高 6.8 个百分点，同时保持 75.133fps 的实时检测能力，满足工业在线检测的效率需求。

1.2.3 YOLO 系列算法

YOLO 作为目标检测领域经典算法，由 Joseph Redmon 等人于 2015 年首次提出^[25]。近年来，伴随更深层次、更为复杂的网络架构相继提出，YOLO 算法的特征提取效能得以持续提升。通过不断的技术迭代更新，YOLO 在速度与精度的均衡性、算法创新性及工程实用性等维度实现显著突破。图 1.1 展示了 YOLO 系列算法的时间发展线，从图中可以看到 YOLO 算法的各个版本的发布时间。




图 1.1 YOLO 系列算法的时间发展线

YOLOv1 开创性地将图像划分为 7×7 网格，每个网格预测 2 个边界框，基于 GoogLeNet 变体的网络结构实现了 45FPS 的实时检测速度，但定位精度较低且召回率不足。次年发布的 YOLOv2^[26]通过引入锚框机制和批归一化技术，在 PASCAL VOC2007 数据集上 mAP 提升至 78.6%，多尺度训练策略进一步增强了模型对不同尺寸目标的适应性。2018 年推出的 YOLOv3^[27]采用 Darknet-53 骨干网络，结合残差连接提升特征提



取能力，并通过三种分辨率的多尺度预测，显著改善小目标检测性能。2020 年，YOLOv4 引入 CSPDarknet53 结构减少计算冗余，配合 Mosaic 数据增强和 CIoU Loss 优化，实现精度与速度的双重突破。同年发布的 YOLOv5 基于 PyTorch 框架重构，提供模块化设计和多尺寸模型，在保持高性能的同时显著降低部署门槛。2022 年的 YOLOv7 通过 E-ELAN 结构优化特征重用，结合动态标签分配策略，在自动驾驶和医疗影像等小目标检测场景中表现出色。YOLOv8 采用无锚框设计，支持动态调整网络结构，模型体积较 YOLOv7 减少 20%，适用于实时边缘计算等资源受限场景。

YOLO 各个版本的骨干网络、关键改进、在 COCO 上的 AP 值的对比如表 1.1 所示。

表 1.1 YOLO 系列对比

版本	骨干网络	关键改进	COCO AP50(%)
YOLOv1	GoogLeNet	端到端回归、网格预测	63.4
YOLOv2	Darknet-19	锚框、多尺度训练	78.6
YOLOv3	Darknet-53	多尺度预测、残差连接	57.9
YOLOv4	CSPDarknet53	Mosaic 增强、CIoU Loss	65.7
YOLOv5	CSPNet	PyTorch 框架、模块化设计	50.7
YOLOv7	E-ELAN	动态标签分配、模型重参数化	56.8
YOLOv8	动态网络	Anchor-Free、实例分割集成	55.8

第二章 相关理论与技术基础

2.1 卷积神经网络基础

2.1.1 网络架构与特征提取机制

卷积神经网络（CNN）作为深度学习领域的关键模型，在图像识别、目标检测等计算机视觉任务中取得了卓越成就。它凭借着独特的网络架构，能够自动地从海量数据当中提取出特征，为复杂的视觉问题解决提供了强大有力的工具。

从宏观架构上看，CNN 主体上可以划分为特征提取层以及分类决策层两个重要阶段，具体细分，则涵盖了输入层、卷积层、池化层、全连接层以及输出层这几个关键部分。如图 2.1 所示。




图 2.1 卷积神经网络架构

输入层用于接收原始数据，这些原始数据通常为图像或者音频信号等形式，随后将其转换为适合处理的格式。卷积层由多个卷积核（filter）组成，每个卷积核会在输入数据上滑动，并与对应的局部区域进行点积运算，进而提取出输入数据里蕴含的特征，由此生成特征图（feature map）。池化层通过降维、特征提取和减少计算量来简化模型结构，同时增强模型的泛化能力。一般而言，池化层都会设置在卷积层之后，主要任务是对卷积层所输出的特征图进行下采样处理。全连接层将前面提取到的一系列特征加以整合，从而输出最终的结果，如分类预测或回归值。激活函数通常在卷积层后应用，引入非线性特性使网络能够学习和表示复杂的特征映射关系。

卷积神经网络的特征提取核心原理主要包括局部感知和权值共享。所谓局部感知，其含义是指卷积核在图像上滑动的过程中，并非着眼于整个图像，而是仅仅关注输入图像的局部区域。这种机制模仿了生物视觉系统中神经元对局部信息的处理方式，使得模

型能够捕捉图像中的边缘、纹理等局部特征。局部感知减少了参数数量，提高了计算效率，并且有助于模型从低级特征逐步提取到高级特征。权值共享是指同一个卷积核在图像的不同位置使用相同的权重进行卷积操作。这一机制减少了参数的数量，降低了模型的复杂度，同时保证了图像的平移不变性，即图像中的特征无论出现在哪个位置都可以被检测到。如此一来，不但提高了模型的泛化能力，还使得模型能够有效处理大规模数据。

2.1.2 目标检测中的多尺度特征融合

在目标检测任务里，图像中目标往往呈现尺度多样性特征。多尺度本质上是对信号进行不同粒度的采样操作，一般而言，在差异化的尺度条件下能够观测到相异的特征，进而完成多样化的任务目标。不同分辨率图像的多尺度特征如图 2.2 所示。




图 2.2 不同分辨率图像的多尺度特征

浅层特征与深层特征具有信息互补性：浅层特征分辨率高，能保留丰富细节；深层特征分辨率低，却包含关键语义信息，可体现整体的趋势。因此多尺度特征融合成为解

决目标检测难题的关键技术。

实现多尺度特征融合的技术主要有特征金字塔网络 (Feature Pyramid Network, FPN)、路径聚合网络 (Path Aggregation Network, PANet)、注意力机制 (Attention Mechanism) 等。FPN 通过自顶向下的路径, 将深层语义特征进行上采样, 并通过横向连接与浅层特征融合, 构建多尺度金字塔结构, 实现了不同尺度特征的有效整合, FPN 的网络结构如图 2.3 所示。




图 2.3 FPN 网络结构

PANet 则是在 FPN 的基础上进行优化, 增加了自底向上的特征传播路径, 进一步强化了低级特征与高级特征之间的交互, 使得网络对多尺度目标的特征表达更为准确, PANet 的网络结构如图 2.4 所示。




图 2.4 PANet 网络结构

注意力机制可以有效帮助模型聚焦于输入图像中最有信息量的部分, 忽略无关的背景信息, 使模型能获取到更多有效的特征^[28]。注意力机制通过通道注意力机制 (Channel Attention Mechanism, CAM) 和空间注意力机制 (Spatial Attention Mechanism, SAM) 的协同作用, 能够自适应地调整特征图的权重分布, 增强网络对关键信息的感知能力。

通道注意力机制主要用于处理特征图通道间的权重分配关系。空间注意力机制可引导神经网络重点聚焦于图像中对分类起关键作用的像素区域，同时抑制无关区域的干扰。通过对通道与空间两个维度进行注意力权重分配，能够显著增强注意力机制对模型性能的优化效果。通道注意力机制与空间注意力机制如图 2.5 所示。




图 2.5 通道注意力机制与空间注意力机制

这些多尺度特征融合技术在 YOLO 系列算法中得到了典型应用。以 YOLOv3 为例，采用多尺度检测头，设置 3 种尺度进行预测，同时结合 FPN+PANet 结构，充分发挥多尺度特征融合的优势，显著增强了对小目标的检测能力，有效提升了整体目标检测的精度与性能，在实际应用场景中取得了良好的效果。

2.2 YOLOv8 算法原理

2.2.1 网络结构

YOLOv8 的网络架构延续了 YOLO 系列经典的单阶段检测框架，由输入端 (Input)、骨干网络 (Backbone)、颈部 (Neck) 和检测头 (Head) 四部分组成。

输入端 (Input) 主要负责数据预处理与增强。预处理包括自适应图像缩放、自适应锚框计算和自适应灰度填充。采用 Mosaic 增强技术，在训练初期随机拼接四张图像，提升模型对小目标和遮挡场景的鲁棒性。骨干网络 (Backbone) 由 CBS 模块、C2f 模块和 SPPF 模块构成。CBS 模块由卷积层、批规范化层和 SiLU 激活函数组成，用于实现

高效特征提取与处理以改进目标检测性能。C2f 模块引入多分支并行结构，通过 Split 操作分割特征图，结合残差连接和密集梯度流，增强特征表达能力，同时保持轻量化。SPPF 模块使用不同尺度的最大池化层聚合多尺度特征，提升模型对不同尺寸目标的鲁棒性。颈部（Neck）采用 PANet 结构，通过双向特征金字塔（FPN+PANet）融合浅层细节信息与深层语义信息，优化小目标检测能力。检测头（Head）采用解耦头设计（Decoupled Head），将分类分支与回归分支分离为独立卷积层。YOLOv8 的网络架构如图 2.6 所示。




图 2.6 YOLOv8 的网络架构

2.2.2 无锚框设计

锚框（anchor boxes）是指在训练过程中，通过先验信息选择固定框的尺寸和比例，以适应训练集中的目标类别和形状^[29]。YOLOv8 摒弃了传统锚框（Anchor-Based）方法，采用无锚框（Anchor-Free）设计，如图 2.7 所示。




图 2.7 传统锚框与无锚框设计对比

对于传统锚框方法而言，需要预先定义不同尺度和宽高比的锚框，进行筛选后再进行分类和回归。在一定程度上能够解决目标尺度不一和遮挡的问题，保证较高的检测精度。然而，锚框设计因复杂度较高且过度依赖人工设计，导致训练与预测流程效率偏低，同时面临正负样本分布失衡的问题。YOLOv8 采用了任务对齐单阶段目标检测 (Task-aligned One-stage Object Detection, TOOD)^[30]的 TAL (Task Alignment Learning) 动态标签匹配策略，从而提高了分类和回归的准确率。首先，将输入图像划分为 $M \times M$ 网格，每个网格直接预测目标中心点的偏移量 (Δx , Δy) 和宽高 (w , h)，无需依赖预定义锚框的尺寸和比例。接着，通过 TAL 策略动态分配正负样本，使分类与回归任务在训练过程中保持一致性，解决锚框分布不均导致的样本失衡问题。

总的来说，无锚框的设计解决了大部分锚框分布在背景区域上导致模型训练时正负样本分配严重不均衡的问题。相较于传统锚框方法，无锚框设计无须设置超参数来限定锚框的尺寸、宽高比与数量，在一定程度上提高了目标检测模型的泛化能力。不但简化模型结构，减少了超参数调优成本，而且能提升对不同长宽比和遮挡场景的适应能力。

2.2.3 损失函数设计

YOLOv8 的损失函数由分类损失和回归损失两部分组成。分类损失沿用二元交叉熵 (Binary Cross-Entropy Loss, BCE Loss)，通过 Sigmoid 函数计算类别概率，用于衡量模型预测的类别概率与真实标签之间的差异，适用于多标签分类场景。分类损失的计算如公式 2-1 所示。

$$L_{cls} = - \sum [y \log(p) + (1 - y) \log(1 - p)] \quad (2 - 1)$$

其中， y 为真实标签，取值为 0 或 1，表示目标是否属于某一类别； p 为预测概率，表示模型预测目标属于某一类别可能性的数值。通过该公式，模型能够学习到如何调整预测概率，使得预测结果尽可能接近真实标签。在实际应用中，通过焦点损失（Focal Loss）优化正样本学习来抑制易分样本，利用在线难例挖掘（OHEM）筛选负样本中的难分样本以平衡正负样本比例。

回归损失结合完全交并比损失（Complete Intersection over Union Loss, CIoU Loss）与分布焦点损失（Distribution Focal Loss, DFL）。完全交并比损失综合考虑重叠面积、中心点距离、长宽比，CIoU Loss 的计算公式如 2-2 所示。

$$L_{CIoU} = 1 - IoU + \frac{\rho^2(b, b^{gt})}{c^2} + \alpha v \quad (2 - 2)$$

其中， ρ^2 为中心点距离， v 为长宽比， c 为包围框对角线长度， α 为长宽比权重。

分布焦点损失将边界框参数建模为离散概率分布，通过 Softmax 生成分布并计算积分得到预测值。DFL 的计算公式如 2-3 所示。

$$L_{DFL} = -[(y_{i+1} - y) \log(S_i) + (y - y_i) \log(S_{i+1})] \quad (2 - 3)$$

其中， y 表示真实边界框的连续坐标值， y_i 、 y_{i+1} 表示与真实值相邻的两个离散位置（满足 $y_i < y < y_{i+1}$ ）， S_i 、 S_{i+1} 表示模型预测的两个离散位置的概率或置信度分数。

2.3 模型评价指标与工业检测需求

2.3.1 通用检测评价指标

在目标检测模型的性能评估体系中，准确率、精确率、召回率、F1 分数及 mAP，从不同维度衡量模型表现，为模型优化与实际应用提供关键依据。

1. 准确率（Accuracy）

准确率作为基础指标，通过计算正确预测样本数占总样本数的比例，直观反映模型在整体样本上的预测准确性。准确率的计算公式如 2-4 所示。

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2 - 4)$$



其中，TP 为真正例，TN 为真反例，FP 为假正例，FN 为假反例。在光伏板缺陷检测中，准确率可以反映整体分类效果，但其局限性在于当正负样本分布不均衡时，准确率可能无法准确反映模型性能。

2. 精确率（Precision）与召回率（Recall）

精确率和召回率则从不同角度刻画模型对缺陷样本的检测能力。精确率聚焦预测结果，计算预测为缺陷的样本中真实缺陷的比例，反映模型降低误检的能力。精确率的计算公式如 2-5 所示。

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2-5)$$

召回率关注实际缺陷样本，计算实际缺陷中被正确检出的比例，体现模型降低漏检的能力。召回率的计算公式如 2-6 所示。

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2-6)$$

3. F1 分数（F1-Score）

在工业应用中，精确率和召回率的权衡至关重要。例如，在安全关键场景，如锂电池表面缺陷检测，因漏检可能引发严重安全事故，需优先保证高召回率；而在误检成本较高的场景，如精密电子元件检测，则要着力提升精确率，减少误判带来的损失。作为精确率与召回率的调和平均数，F1 分数对类别不平衡数据尤为敏感，有效平衡了两者间的矛盾。F1 分数的计算公式如 2-7 所示。

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2-7)$$

4. 平均精度均值（Mean Average Precision, mAP）

在目标检测任务中，通常需要检测多个类别。mAP 是通过对所有类别的平均精度（Average Precision, AP）求平均值，用于衡量模型在全类别上的平均检测性能。mAP 的值介于 0 到 1 之间，数值越趋近于 1，表明模型性能越优；反之，数值越趋近于 0，则意味着模型性能越差。mAP 的计算公式如 2-8 所示。

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^N \text{AP}_i \quad (2-8)$$

其中，N 为类别总数， AP_i 表示第 i 个类别的平均精度。



2.3.2 光伏板缺陷检测的特殊性要求

光伏板缺陷检测因应用场景的特殊性，在环境适应性、技术实现和工程落地中面临着诸多挑战与需求。作为长期暴露于户外的发电设备，光伏板的检测性能直接受复杂环境因素影响。光照强度的动态变化导致图像采集时亮度不均，进而影响视觉检测算法的稳定性；温度波动不仅改变半导体材料的电学特性，还可能使红外热成像检测中缺陷区域的温度特征被环境噪声掩盖；高湿度环境易引发表面结露或材料腐蚀，造成检测图像模糊或信号失真；风速、降水、污染及积雪等因素通过物理损伤、表面遮挡等方式进一步干扰检测信号的准确性与完整性。这些环境变量的叠加效应，降低了检测数据的信噪比，显著增加了缺陷特征提取的难度，要求模型具备针对复杂环境下的细粒度特征提取能力。

在光伏板检测的技术实现层面，多种检测技术的互补应用成为关键技术路径。红外热成像通过捕捉温度异常识别划痕、断栅等内部缺陷，电致发光（Electroluminescence, EL）技术借助发光特性定位微观结构损伤，而基于深度学习的视觉算法则擅长处理表面污渍、破损等可见缺陷。

然而，光伏板检测行业发展仍面临多重挑战。其中一大障碍是复杂的环境因素。户外检测中，红外图像常因温差不足导致缺陷边界模糊，EL 图像易受环境光干扰产生噪声，同时传统视觉算法在灰尘覆盖或低对比度场景下的漏检率显著上升。缺陷本身的多样性与尺度变化对算法鲁棒性提出了更高要求，划痕可能表现为微米级的细缝，断栅缺陷的形态随电池片结构差异而变化，脏污类缺陷的颜色、纹理与背景高度相似，这些差异要求检测模型具备更强的特征泛化能力。在数据处理与模型优化方面，海量检测数据的实时分析对边缘计算设备的算力提出挑战，而深度学习依赖的大规模标注数据在工业场景中获取成本高昂，如何通过小样本学习或迁移学习降低数据门槛，成为算法落地的关键问题。

第三章 基于 YOLOv8 光伏板缺陷检测算法

3.1 光伏板缺陷数据集构建

3.1.1 数据集的预处理

本文构建了面向光伏板表面缺陷检测的专业数据集，针对三种典型缺陷——划痕（Crack）、断栅（Grid）、脏污（Spot），采用 LabelImg 工具进行人工精细化标注，以确保标注边界的精度。原始图像经标准化处理后生成 PASCAL VOC 格式标注文件，每个缺陷实例均包含精确的边界框坐标与类别信息。然后进行数据集的格式化处理，将标注后的数据，从 XML 格式转换为 YOLO 格式，为之后的模型训练。光伏板表面缺陷类型如图 3.1 所示。




图 3.1 光伏板表面缺陷类型示例

数据集共包含 2,400 张现场采集图像。为了保证接下来模型能更好地使用该数据集进行训练，依据机器学习标准规范，按照 6:2:2 的比例对数据集进行数据划分。划分后得到训练集 1,440 张，验证集 480 张，测试集 480 张。特别采用分层抽样策略，保证各类别缺陷在子集中的比例分布与总体一致，避免因数据分布不均匀导致的模型偏差。至此，数据集的预处理就完成了。

3.1.2 数据分布特性分析

通过对数据集进行多维度统计分析发现：

(1)本数据集中每张图片的缺陷数量的分布情况如图 3.2 所示。由图可以得知，单位图像缺陷密度呈现长尾分布，其中单缺陷样本占比 91.67%（2,200 张），双缺陷样本占

7.5%（180 张），多缺陷样本仅占 0.83%（20 张），该分布特征与工业质检场景的实际情况相符；




图 3.2 每张图像的缺陷数量分布

(2)本数据集的缺陷类别的分布情况如图 3.3 所示。说明类别平衡性方面，Crack（892 张）、Grid（884 张）、Spot（852 张）三类样本量差异小于 5%，均衡的数据分布为模型公平学习各类缺陷特征奠定基础。




图 3.3 数据集缺陷类别分布



3.2 基于 YOLOv8 的模型优化

3.2.1 实验环境

本文的实验环境如表 3.1 所示。

表 3.1 本文的实验环境

实验环境	版本/型号
操作系统	Windows 10
GPU	NVIDIA GeForce RTX 3050
编译语言	Python 3.9.13
深度学习框架	PyTorch 2.0.1 + CUDA 11.7.1
目标检测库	Ultralytics 8.3.76
开发工具	PyCharm 2024.1

3.2.2 动态学习率策略与优化器

在深度学习的优化算法领域，优化器的选择对模型训练效果有着举足轻重的影响。其中，随机梯度下降（Stochastic Gradient Descent，SGD）凭借其简单的梯度下降原理，通过逐批次更新参数推动模型训练进程，成为深度学习中应用广泛的经典算法。其算法结构简洁，计算过程高效，在训练初期能够快速引导模型参数向最优解方向更新。然而随着训练周期增大，缺陷检测的 mAP 值易出现波动，以至于容易出现收敛的问题。光伏板缺陷的梯度信号较弱，SGD 容易因学习率调节不当导致漏检。

Adam（自适应矩估计）作为 SGD 的改进算法，融合了 Momentum 优化方法和 RMSProp 优化方法的优势，能够有效提升优化算法的精度。可以根据训练过程自动调整学习率，极大地减少了人工参数调整的繁琐工作。

AdamW 则是在 Adam 基础上的进一步革新，通过解耦权重衰减（Weight Decay）与参数更新的方式，成功解决了传统 Adam 中正则化项与自适应学习率的耦合偏差问题。这种改进使得 AdamW 在处理复杂任务时，能够更加合理地对模型参数进行优化。

3.2.3 正则化技术应用

在模型训练中，正则化技术通过约束模型参数复杂度以提升泛化能力，本文采用了



权重衰减作为核心正则化手段。具体而言，在目标函数中引入 L2 正则化项，对网络权重的平方范数施加惩罚，迫使模型学习更小的权重值，从而抑制过拟合现象。权重衰减系数用于控制正则化强度。在数学表达上，整体损失函数由分类损失、回归损失与正则化项构成。如公式 3-1 所示。

$$L = L_{\text{cls}} + L_{\text{reg}} + \lambda \sum_i \|w_i\|^2 \quad (3-1)$$

式中， L_{cls} 为分类损失， L_{reg} 为回归损失， λ 为权重衰减系数， $\sum_i \|w_i\|^2$ 表示对模型所有可训练权重 w_i 的 L2 范数平方求和。通过该机制，模型在优化过程中不仅最小化分类与定位损失，同时对复杂权重组合产生抑制作用，促使网络参数分布更趋向简洁，有效降低因参数冗余导致的过拟合风险，保障了模型在光伏板缺陷识别任务中的稳健性。

3.2.4 增量训练策略

增量训练（Incremental Training）是一种逐步更新模型参数的训练方法，核心在于利用已有模型的知识，仅对新数据或新任务进行部分调整，避免重复训练全部参数。本文采用三阶段渐进式训练策略，通过逐步优化模型结构、学习策略与数据增强方案，实现检测性能的显著提升。

首次训练基于 YOLOv8n 预训练模型，采用 SGD 优化器与余弦退火学习率策略，并结合高强度数据增强，完成了 200 个 Epochs 的训练。其中，Mosaic 概率为 0.7，Mixup 概率为 0.15，Hsv_h 扰动为 0.05，Hsv_s 扰动为 0.7，Hsv_v 扰动为 0.3。实验结果表明，模型在验证集上整体 mAP50 达到 0.927，其中 Crack 类别的精确度（0.942）与召回率（0.952）表现突出，但 Grid 类别因小目标特性导致 mAP50-95 仅为 0.409。分析认为，过强的数据增强可能破坏小目标的上下文关联性，同时 SGD 优化器在复杂参数空间中易陷入局部最优，限制了模型对多尺度特征的适应性。第一阶段训练结果如表 3.2 所示。

表 3.2 第一阶段训练结果

类别	精确度（P）	召回率（R）	mAP50	mAP50-95
Crack	0.942	0.952	0.973	0.511
Grid	0.878	0.867	0.905	0.409
Spot	0.884	0.839	0.904	0.460
整体	0.901	0.886	0.927	0.460



为解决基线模型的局限性，第二阶段引入 AdamW 优化器，通过自适应动量调整提升参数更新稳定性，同时扩大余弦退火范围（最终学习率 lrf 从 0.05 调整为 0.1），并延长预热周期至 15 个 Epochs 以平滑学习率变化。总共完成了 100 个 Epochs 的训练。数据增强强度适度降低（Mosaic 概率降低至 0.6，Mixup 概率降至 0.1，Hsv_h 扰动降低至 0.03 避免颜色失真），损失函数中分类任务权重（Cls 增益）从 1.2 提升至 1.5，强化模型对类别特征的区分能力。优化后 Grid 类别召回率从 0.867 显著提升至 0.914，整体 mAP50 提高至 0.934，验证集推理速度稳定在每张图片 2.5ms。这一改进验证了自适应优化器在平衡模型收敛速度与精度方面的优势，尤其缓解了小目标检测中梯度方向不一致的问题。第二阶段训练效果如表 3.3 所示。

表 3.3 第二阶段训练结果

类别	精确度（P）	召回率（R）	mAP50	mAP50-95
Crack	0.941	0.952	0.974	0.519
Grid	0.878	0.914	0.909	0.432
Spot	0.878	0.865	0.920	0.469
整体	0.899	0.910	0.934	0.473

在前两阶段基础上，第三阶段聚焦于高阶特征表达能力的优化。完全关闭 Mosaic 与 Mixup 增强，减少数据分布偏差对特征学习的干扰。进一步降低初始学习率以细化参数更新。本次训练继续沿用 AdamW 优化器，完成了 80 个 Epochs 的训练。实验结果显示，Crack 类别的 mAP50-95 提升至 0.532（较第一阶段提升 4.1%），Spot 类别召回率从 0.865 提升至 0.899，表明模型在复杂背景下的泛化能力显著增强。尽管对于单帧的推理耗时轻微上升至 4.5 毫秒，但仍然满足工业检测场景的实时性需求（<5ms/image）。第三阶段训练效果如表 3.4 所示。

表 3.4 第三阶段训练结果

类别	精确度（P）	召回率（R）	mAP50	mAP50-95
Crack	0.924	0.952	0.979	0.532
Grid	0.901	0.937	0.931	0.440
Spot	0.877	0.899	0.918	0.478
整体	0.901	0.929	0.943	0.483



总的来说，三阶段优化使模型在保持实时性（ $<5\text{ms/image}$ ）的前提下，mAP50-95 从 0.460 提升至 0.483。AdamW 优化器与动态数据增强策略的组合，有效平衡了模型对多尺度目标的检测能力。

3.2.5 注意力机制

CBAM（Convolutional Block Attention Module）^[31]注意力机制是由通道注意力机制和空间注意力机制组成。在本实验中，将 CBAM 模块插入在 Backbone 的第 9 层，也就是在 C2f 模块之后，SPPF 层之前。

为了方便对照，更直接的反应加入 CBAM 注意力机制对本实验的影响，采用了默认的训练超参数来控制变量。不引入 CBAM 注意力机制与引入 CBAM 注意力机制的训练结果分别如表 3.5 和表 3.6 所示。

表 3.5 不引入注意力机制的训练结果

类别	精确度（P）	召回率（R）	mAP50	mAP50-95
Crack	0.904	0.946	0.968	0.463
Grid	0.873	0.872	0.900	0.425
Spot	0.844	0.871	0.900	0.410
整体	0.874	0.897	0.923	0.433

表 3.6 引入注意力机制的训练结果

类别	精确度（P）	召回率（R）	mAP50	mAP50-95
Crack	0.904	0.935	0.963	0.472
Grid	0.847	0.900	0.882	0.421
Spot	0.884	0.816	0.901	0.427
整体	0.878	0.884	0.915	0.440

实验数据显示，基线模型（无 CBAM）在 mAP50 指标上达到 0.923，反而略高于 CBAM 增强模型的 0.915。这种反直觉现象揭示了两个潜在问题：其一，当前数据集的缺陷形态具有高度规律性（如栅线断裂多呈现直线状），使得基础卷积网络已能通过常规特征提取捕获判别性模式；其二，光伏板图像中存在的亮度不均和反光干扰，导致注意力机制错误强化了非缺陷区域的伪特征，可以看到 CBAM 模型中 Grid 类别的 mAP50



相较于基线模型下降了 1.8%，尤为明显。

本文中引入 CBAM 注意力机制未能显著提升模型性能，可能与任务特性及数据分布密切相关。首先，光伏板缺陷（如断栅、划痕）通常呈现为局部微弱的纹理变化，其有效特征区域往往仅占图像极小比例（多数缺陷面积占比低于 1%）。在这种情况下，标准 CBAM 的通道注意力模块通过全局平均池化聚合特征时，容易被大面积正常区域主导，导致缺陷特征在通道重标定过程中被弱化。其次，空间注意力模块依赖的 7×7 卷积核在捕捉亚像素级缺陷时，可能因感受野过大而引入背景噪声，这点在可视化实验中体现为注意力热图未能精准聚焦于裂纹边缘等关键区域。这些发现表明，通用注意力机制在工业质检场景中的应用需谨慎，其有效性高度依赖缺陷的显著性程度与数据分布的适配性。

3.3 关键问题与解决方案

3.3.1 图像增强策略

在模型训练中，常常使用图像增强技术来提升数据多样性，进而增强模型泛化能力。通过调整参数，对训练图像进行多样化随机变换。在颜色特征层面，通过设置 `Hsv_h`、`Hsv_s`、`Hsv_v`，对图像的色调、饱和度和亮度进行随机扰动，模拟不同光照条件下光伏板表面的色彩差异。在几何变换层面，利用 `Degrees` 控制随机旋转角度，`Translate` 限定平移范围，`Scale` 设定缩放比例，使模型适应缺陷目标在图像中的位置偏移与尺度变化。为进一步丰富样本信息，引入 `Mosaic` 和 `MixUp` 增强策略。`Mosaic` 表示以设定参数的概率随机拼接 4 张图像，迫使网络学习跨图像的上下文关联特征，增加背景复杂度以增强泛化能力；`Mixup` 则以设定参数的概率混合两张图像的内容，促进类别特征的交叉学习。同时，`Fliplr` 参数控制图像进行水平翻转，通过对称变换扩大样本空间。

以上的增强操作在训练过程中动态生成多样化样本，为光伏板表面缺陷特征的鲁棒学习提供了丰富的训练素材。

3.3.2 分类损失震荡优化策略

在模型训练初期，分类损失（`cls_loss`）呈现剧烈震荡，严重阻碍模型收敛。在首次训练中，采用 SGD 优化器，配合高强度的 `Mosaic` 与 `Mixup` 的数据增强，导致输入数据的分布动态变化剧烈。`Mosaic` 增强将四张图像拼接后，目标尺度与上下文关系的突变使

得分类特征学习难度增加。Mixup 生成的混合标签进一步引入噪声信号。此时模型尚未建立稳定的特征表示能力，分类层参数在强梯度扰动下频繁振荡。另外，本文采用的数据集尽管整体分布相对均衡，但 Grid 类别因小目标特性导致有效特征信息稀疏，模型在初期难以区分其与背景的细微差异。不仅如此，部分 Spot 样本因光照不均呈现与 Crack 样本相似的纹理特征，标签歧义性使得分类置信度反复调整。

为了解决这个问题，考虑将 SGD 优化器替换为 AdamW 优化器，利用其自适应动量机制平滑梯度方向，使 cls_loss 波动范围缩小；逐步降低 Mosaic 概率与 Mixup 概率，减少噪声标签生成频率。实验结果表明，上述调整使分类损失 14.275 收敛于 2.113。

3.3.3 小目标检测增强策略

为消除数据偏倚风险并确保样本空间分布的均衡性，本文采用分层随机抽样策略从完整标注集中抽取 100 张样本图像。通过定量分析缺陷区域与图像有效面积的相对比例，发现不同缺陷类型呈现出显著的小目标特性。




图 3.5 缺陷区域和比例的分布比较

缺陷区域的大小与其占图像有效面积的相对比例的箱线图如图 3.5 所示，其中左侧图像代表缺陷区域的尺寸分布情况，右侧图像代表缺陷区域在图像有效面积的相对比例。经过对缺陷区域的分析可以得知，Spot 类别面积的中位数为 4278 像素，缺陷区域面积相对于图像有效面积的占比中位数为 0.51%；Grid 类别面积的中位数为 1728 像素，面积占比中位数为 0.22%；Crack 类别的面积中位数为 4316 像素，面积占比中位数为 0.53%。

该统计结果表明，光伏缺陷对检测模型的特征提取能力要求较高，对模型的训练有着严峻的挑战。

基于此发现，后续算法设计需着重考虑以下增强策略：首先，采用 Mosaic 增强，每次训练时按一定概率将四张图像拼接训练，通过场景重构增强模型对复杂背景的适应能力。其次，设置 Mixup 实施线性图像混合，通过特征空间的凸组合生成过渡样本。该策略在扩充数据多样性的同时，缓解因小目标样本不足导致的过拟合风险。此外，尝试使用 Copy-paste 增强，从有缺陷的图片中抠取缺陷区域，将缺陷以随机尺度、旋转角度粘贴到正常样本的合理位置，以此来增强模型对缺陷特征的敏感性和定位能力。然而，经实验验证，Copy-paste 增强在本实验环境中会导致显存溢出风险，且引入的边界伪影使验证集噪声敏感度上升。权衡性能与稳定性后，最终禁用该增强策略。

3.4 实验结果分析

3.4.1 PR 曲线

PR 曲线（Precision-Recall Curve）展示了不同阈值下分类器的精确率（Precision）和召回率（Recall）。具体来说，横轴表示，召回率范围从 0.0 到 1.0；纵轴表示，精确度范围从 0.0 到 1.0。本实验的精确度-召回率曲线如图 3.6 所示。




图 3.6 PR 曲线

图中主要有四条曲线，分别代表 Crack 类别的 PR 曲线、Grid 类别的 PR 曲线、Spot 类别的 PR 曲线以及所有类别的平均 PR 曲线。由图可以看出，Crack 类别的精确度在 0.979 左右保持稳定，Grid 类别的精确度在 0.931 左右保持稳定，Spot 类别的精确度在 0.918 左右保持稳定。所有类别的平均精确度在 0.943 左右保持稳定。

曲线显示了随着召回率的增加，精确度略有下降的趋势，但整体上精确度保持在较高的水平。不难看出，分类器在识别 Crack 类别时表现非常出色，具有很高的准确性和稳定性。

3.4.2 F1 分数

F1 分数（F1-Confidence Curve）是精确率（Precision）和召回率（Recall）的调和平均值，它同时考虑了模型预测的准确性和覆盖面。F1 分数的范围从 0 到 1，其中 1 表示模型的精确率和召回率都是完美的，而 0 则表示模型的精确率或召回率至少有一个非常差。本实验的 F1 分数曲线如图 3.7 所示。




图 3.7 F1 分数

从图中可以看出，当置信度（Confidence）为 0.244 时，所有类别（all classes）的 F1 分数为 0.92。这表明模型在当前置信度下，对各类别目标的检测既保持了较高的精确率，又实现了较高的召回率。

3.4.3 混淆矩阵及其归一化

混淆矩阵（Confusion Matrix）以实际类别和模型预测类别为基础，将样本分类结果进行统计和汇总。混淆矩阵是一个 $n*n$ 的矩阵，其中 n 表示类别的数量。每行代表实际类别，每列代表模型预测的类别。对角线上的值表示模型正确分类的数量，非对角线上的值表示分类错误的数量，并且颜色越深表示数量越多。

本实验的混淆矩阵如图 3.8 所示。由图可知，有 180 个 Crack、155 个 Grid、158 个 Spot 被正确分类。有 8 个 Crack、11 个 Grid、15 个 Spot 被错误分类为 background。




图 3.8 混淆矩阵

归一化混淆矩阵（Confusion Matrix Normalized）是对混淆矩阵归一化处理的结果，将每个单元格的值除以该类别实际样本数，从而得到表示分类准确率的百分比。归一化可以直观地比较类别间的分类准确率，并识别出模型在哪些类别上表现较好或较差。归一化混淆矩阵如图 3.9 所示。




图 3.9 混淆矩阵归一化

从图 3.9 中可以看出，当预测为 Crack 类缺陷时，实际也为 Crack 类缺陷的概率为 0.97；当预测为 Grid 类缺陷时，实际也为 Grid 类缺陷的概率为 0.93；当预测为 Spot 类缺陷时，实际也为 Spot 类缺陷的概率为 0.91。Crack 被错误分类为 background 的比例为 0.03，Grid 被错误分类为 background 的比例为 0.07，Spot 被错误分类为 background 的比例为 0.09。这表明该模型在光伏板表面缺陷检测方面具有很高的准确性。

第四章 光伏板缺陷检测系统设计与实现

4.1 检测流程设计

本系统的检测流程主要分为四个阶段：模型加载、图片选择、缺陷检测和结果展示。系统检测流程如图 4.1 所示。




图 4.1 系统检测流程图

在模型加载阶段，用户点击“选择模型文件”按钮，通过文件选择对话框选择训练好的模型文件（.pt 格式）。系统将显示所选模型文件名，并启用“初始化模型”按钮。用户点击该按钮后，系统进行模型加载和预热检测。在初始化成功后，系统启用图片选择功能，并在状态栏显示提示信息。这种依次启用选择按钮的设计，能对用户进行良好的引导，降低系统的使用门槛。接下来是图片选择阶段，用户可以选择单张图片检测或批量检测模式。若为单张图片检测，点击“选择图片文件”按钮选择待检测图片；若是批量检测，则点击“选择图片文件夹”按钮，选择包含多张图片的文件夹。系统会实时显示所选图片或文件夹的名称。在缺陷检测阶段，用户点击“开始检测”按钮启动检测



过程。单张图片检测时，系统直接对选中的图片进行检测；批量检测时，系统依次处理文件夹中的所有图片，并显示进度对话框。检测过程中，系统实时计算并显示检测耗时。最后是结果展示阶段，检测完成后，系统在中间面板显示标注后的检测结果图像，右侧面板显示检测到的缺陷类型、置信度和检测时间，同时检测结果自动添加到历史记录表格中，用户可以通过点击历史记录中的条目查看历史检测结果，并支持将检测结果导出为 CSV 格式文件。

4.2 基于 PyQt 的页面搭建

4.2.1 PyQt 介绍

PyQt 是基于 Python 语言的跨平台 GUI 开发框架，通过封装 Qt 框架的 C++ 库为 Python 模块，为工业检测系统提供了高效的界面开发解决方案。其核心价值体现在跨平台兼容性上，开发者可使用同一套代码在 Windows、Linux 和 macOS 系统上部署检测界面，例如在混合使用 Windows 工控机和 Linux 服务器的光伏板检测产线中，显著降低了多平台适配成本。

PyQt 采用信号与槽（Signals & Slots）机制实现界面与逻辑的解耦，该机制通过事件驱动方式传递数据。在缺陷检测场景中，当后端算法识别到光伏板表面划痕时，可通过信号自动触发界面更新检测结果，避免因数据阻塞导致的界面卡顿问题。配合内置的 Qt Designer 可视化工具，开发者可通过拖拽组件快速构建工业检测界面原型，例如整合图像显示区、参数配置面板和实时数据图表，大幅缩短开发周期。

4.2.2 PyQt 功能模块实现

本系统基于 PyQt5 框架开发了图形界面，以达到更好的用户交互效果。在模型加载模块中，采用文件选择对话框与异步加载机制的组合设计，这能让用户能根据自己的需要，自主选择适合的模型文件来实现检测功能。为了在首次检测时，获得更加流畅的体验，引入了预热检测功能。这不仅能预先排除模型加载异常，还为后续检测流程的稳定性奠定基础，有效避免了界面卡顿现象。

针对实际应用场景中的差异化需求，设计了单图检测模式与多图批处理检测这两种模式。单图检测模式允许用户选择一张符合格式的图片，这能满足用户快速验证的调试需求；批量模式实现了对文件夹的选择，大大提高了对批量规模数据的处理效率。两种

模式共享统一的进度可视化组件，既保证了操作过程的可控性，又降低了任务异常终止带来的数据丢失风险。点击“开始检测”按钮后，所选图片文件或文件夹将依照规定模型进行检测。检测结果图像展示区域将显示缺陷的具体位置、缺陷类型与置信度，并且标注用时。此外，检测历史记录中将记录本次运行周期中的所有检测数据，包括图片名称、缺陷类型、置信度、检测时长等，这也将与结果导出功能的数据一致。

在结果导出模块的设计中，采用结构化数据与可视化结果并存的存储策略。CSV 格式的检测报告通过标准字段记录关键检测参数，确保数据分析的便捷性与可追溯性；同步生成的标注图像则采用无损压缩格式，为人工复核提供直观依据。编码格式上选用 UTF-8 标准，解决了中文路径的兼容性问题。

4.3 检测结果可视化方案

界面布局采用经典的三栏式设计，符合人机交互习惯，有利于用户更好上手使用。左侧控制面板集中配置核心操作组件，通过功能按钮的分组排列，引导用户依次点击；中央显示区域采用自适应画布技术，在保证图像原始比例的前提下，提供缩放与拖拽功能以辅助细节观察；右侧信息面板通过分层折叠式设计，在有限空间内整合了缺陷属性、置信度分布及耗时统计等多个数据。检测系统界面如图 4.2 所示。



图 4.2 检测系统界面



系统检测 Spot 缺陷、Crack 缺陷、Grid 缺陷的示例图分别如图 4.3、图 4.4、图 4.5 所示。对于存在多种缺陷种类的图像检测如图 4.6 所示。



图 4.3 系统检测 Spot 缺陷示例




图 4.4 系统检测 Crack 缺陷示例



图 4.5 系统检测 Grid 缺陷示例



图 4.6 系统检测存在多种缺陷种类的图像示例



可视化方案应该着重展示缺陷信息的直观。因此，为不同缺陷类型分配高对比度标识色，提升对不同分类的辨识速度。置信度渲染采用同一色系，同样帮助用户快速聚焦高置信度目标。在缺陷类型和置信度表格的下方，耗时统计模块实时更新检测进程的时间开销，其数据记录功能为系统性能优化提供了量化依据。



第五章 总结与展望

5.1 研究总结

本文围绕光伏板表面缺陷检测的工业需求，以 YOLOv8 算法为核心框架，构建了覆盖划痕、断栅与脏污三类典型缺陷的光伏板图像数据集，并通过增量训练方法进行优化，显著提升了模型在复杂场景下的检测性能。针对光伏缺陷的小目标特性与数据分布特征，提出基于多尺度特征融合的增强策略，调整动态学习率策略、正则化技术，通过 Mosaic 增强与自适应 HSV 扰动强化模型对微小缺陷的感知能力，同时采用 AdamW 优化器与分类损失震荡抑制方法，有效平衡了训练过程中的梯度稳定性与特征泛化性。实验结果表明，经过三阶段的增量训练后，模型在测试集上的整体 mAP50 达到 94.3%，其中断栅类别的召回率从初始阶段的 86.7% 提升至 93.7%，验证了优化策略对小目标检测的有效性。此外，本文设计并实现了基于 PyQt 的缺陷检测系统，通过模块化交互界面与双模式检测流程，将单张图像推理时间控制在 4.5ms 以内，支持检测结果的可视化标注与结构化导出，为光伏电站的智能化运维提供了完整的算法与工程解决方案。

5.2 未来改进方向

本文虽在光伏板缺陷检测精度与系统实用性方面取得一定突破，但仍有一些方面有待深化探索。目前所使用的数据集虽已涵盖三类典型缺陷，但在应对反光、阴影等复杂环境干扰时，仍显示出鲁棒性不足的问题。针对这一不足，未来可考虑融合可见光、EL 成像与热红外等多种模态数据，构建跨光谱特征表达空间。同时，借助物理仿真技术，例如 COMSOL 光场模拟，生成包含动态背景噪声的合成样本。这一方法有望有效解决户外强光反射与雨雪遮挡场景下数据稀缺的问题。此外，结合迁移学习框架，将钢材表面缺陷检测中的自适应空间特征融合（ASFF）模块适配到光伏场景中，以此增强对纹理复杂区域的特征提取能力。

对于断栅类缺陷 mAP50-95 较低（0.440）的问题，需要突破现有单尺度特征提取的局限。为此，可设计动态特征融合网络，通过结合 Transformer 与 CNN 的混合架构，实现对多尺度缺陷的自适应感知。利用自注意力机制，能够捕捉长距离上下文依赖关系，从而强化微小缺陷的语义关联性。同时，开发轻量化的注意力机制，并引入可微分空间剪枝模块，为边缘端部署提供更加轻量化的解决方案。



总体而言，这些改进方向紧密贴合光伏行业的实际需求，从数据驱动、算法创新到系统落地，形成完整的技术闭环。这为构建高精度、高鲁棒性的光伏电站智能运维体系提供了可行的路径。



参考文献

- [1] 孙立江.太阳能光伏发电技术的应用研究[J].中国设备工程,2025,(03):241-243.
- [2] 张翼.以“新”铸型,电力未来正来[N].光明日报,2025-02-28(005).DOI:10.28273/n.cnki.ngmrb.2025.001169.
- [3] 李世民,喜文华.光伏板热斑对发电性能的影响[J].发电设备,2013,27(1):61-63.
- [4] LIENHART R, MAYDT J. An extended set of haar-like features for rapid object detection; proceedings of the Proceedings international conference on image processing, F, 2002[C]. IEEE.
- [5] LINDEBERG T. Scale invariant feature transform[J]. Scholarpedia, 2012,7(5), 10491.
- [6] HEARST M A, DUMAIS S T, OSUNA E, et al. Support vector machines[J]. IEEE Intelligent Systems and their applications, 1998, 13(4): 18-28.
- [7] AHMED A, JALAL A, KIM K. Region and decision tree-based segmentations for Multiobjects detection and classification in Outdoor Scenes[C]//2019 International Conference on Frontiers of Information Technology (FIT). IEEE, 2019: 209-2095.
- [8] YING C, QI-GUANG M, JIA-CHEN L, et al. Advance and prospects of AdaBoost algorithm[J]. Acta Automatica Sinica, 2013, 39(6): 745-758.
- [9] Viola P, Jones M. Robust real-time object detection//Proceedings of the 2nd International Workshop on Statistical and Computation Theories of Vision-Modeling, Learning, Computing and Sampling. Vancouver, Canada, 2001:34-47
- [10] N Dalal, B Triggs. Histograms of Oriented Gradients for Human Detection [J]. IEEE Computer Society Conference on Computer Vision & Pattern Recognition, 2005, 1(12): 886-893.
- [11] P. Felzenszwalb, D. McAllester, D. Ramanan A Discriminatively Trained, Multiscale, Deformable Part Model IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2008
- [12] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. Advances in Neural Information Processing Systems, 25, 1097-1105.
- [13] Simonyan, K., & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. In International Conference on Learning Representations.
- [14] C. Szegedy et al., "Going deeper with convolutions," in IEEE Conference on Computer Vision and Pattern Recognition, 2015, pp. 1-8.
- [15] 杨子房,袁家政,徐成,等.基于YOLO系列的目标检测研究进展综述[C]//中国计算机用户协会网络应用分会.中国计算机用户协会网络应用分会2024年第二十八届网络新技术与应用年会论文集.北京联合大学北京市信息服务工程重点实验室;北京联合大学机器人学院脑与认知智能北京实验室;北京开放大学;;2024:5.DOI:10.26914/c.cnkihy.2024.047826.
- [16] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition. Columbus, OH, USA: IEEE, 2014:580-587.
- [17] HE K, ZHANG X, REN S, et al. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition.[C]//European Conference on Computer Vision Springer, Cham, 2014, 36(87): 346-361.
- [18] GIRSHICK R. Fast R-CNN[C]//2015 IEEE International Conference on Computer Vision (ICCV). Santiago, Chile: IEEE, 2015:1440-1448.
- [19] REN SH Q, HE K M, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine



- Intelligence,2016,39(6):1137-1149.
- [20] He K,Gkioxari G,Dollár P,et al.Mask r-cnn [C].Proceedings of the IEEE international conference on computer vision.2017:2961-2969.
- [21] LIU W,ANGUELOV D,ERHAN D,et al.SSD:single shot multibox detector[C]//European Conference on Computer Vision.Springer,Cham,2016:21- 37.
- [22] Lin TY,Goyal P,Girshick R,et al.Focal loss for dense object detection[C]//Proceedings of the IEEE International Conference on Computer Vision,2017:2980-2988.
- [23] 王宪保,李洁,姚明海,等.基于深度学习的太阳能电池片表面缺陷检测方法[J].模式识别与人工智能,2014,27(06):517-523.DOI:10.16451/j.cnki.issn1003-6059.2014.06.006.
- [24] 涂俊博,曾佳林,唐越新,等.基于深度学习的太阳能电池板表面缺陷检测及分类[J].激光与光电子学进展,2025,62(02):456-465.
- [25] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once:unified, real-time object detection[C]//Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, Jun 27-30, 2016. Washington:IEEE Computer Society, 2016:779-788.
- [26] EDMON J, FARHADI A. YOLO9000:better, faster, stronger[C]//Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Washington:IEEE Computer Society, 2
- [27] REDMON J, FARHADI A. YOLOv3:an incremental improvement[EB/OL].
- [28] 冯小丹,云利军,高海峰,等.机器视觉注意力机制研究综述[J/OL].云南民族大学学报(自然科学版),1-14[2025-05-19].<http://kns.cnki.net/kcms/detail/53.1192.N.20250326.1026.004.html>.
- [29] 徐彦威,李军,董元方,等.YOLO 系列目标检测算法综述[J].计算机科学与探索,2024,18(09):2221-2238.
- [30] Feng C J, Zhong Y J, Gao Y, et al. TOOD: task-aligned one-stage object detection [C] //2021 IEEE/CVF International Conference on Computer Vision (ICCV) . Montreal, 2021: 3490-3499.
- [31] WOO S, PARK J, LEE J Y, et al. CBAM: convolutional block attention module[C]//Proceedings of the European Conference on Computer Vision (ECCV).Cham:Springer, 2018: 3-19.



致谢

在本科生涯即将结束之际，谨向所有给予过我温暖力量的存在致谢。

感谢家人在我求学生涯中多年如一的支持，感谢朋友们给予的珍贵陪伴，感谢老师与学姐对本篇论文成果的悉心指导，以及感谢音乐赋予我的精神力量。

当我遇到重压忧愁，我灵却常得自由。我也向始终保持韧性的自己表示感谢。于我而言，这四年的时间是一场向内的探索——寻找自己、理解自己和接受自己的过程。在迷茫和低谷中不愿沉溺，在混沌和怀疑下努力清醒。值得庆幸的是，我依然是那个最初的我。