



貴州大學

本科毕业论文（设计）

论文（设计）题目：基于深度学习的单目 3D 目标检测算
研究

学 院： 计算机科学与技术学院（贵州保密学院）

专 业： 计算机科学与技术

班 级： 计科 2103

学 号： 2100170266

学生姓名： 赵丽娜

指导教师：

2025 年 5 月 30 日

贵州大学本科毕业论文（设计）

诚信责任书

本人郑重声明：本人所呈交的毕业论文（设计），是在导师的指导下独立进行研究所完成。毕业论文（设计）中凡引用他人已经发表或未发表的成果、数据、观点等，均已明确注明出处。

特此声明。

论文（设计）作者签名： 赵丽娜

日 期： 5月30日



目录

摘要	III
Abstract	IV
第一章 绪论	1
1.1 研究背景	1
1.2 国内外研究现状	2
1.2.1 3D 目标检测研究现状概述	2
1.2.2 基于单目视觉的 3D 目标检测研究现状	3
1.2.3 当前挑战与研究趋势	5
1.3 论文的主要研究内容与章节安排	5
第二章 深度学习理论基础	7
2.1 卷积神经网络	7
2.1.1 卷积层	7
2.1.2 池化层	8
2.1.3 激活函数	9
2.1.4 全连接层	10
2.1.5 损失函数	10
2.2 目标检测算法基础	12
2.2.1 双阶段检测算法	12
2.2.2 单阶段检测算法	13
第三章 基于样本选择的单目三维目标检测方法	15
3.1 基于样本选择的单目方法详述	15
3.2 物理约束数据增强	17
3.3 自适应特征采样模块	18
3.3.1 基于概率扰动的自适应样本选择机制	19
3.3.2 相对距离样本划分策略	20
3.4 损失函数和训练策略	20
第四章 实验结果与分析	23
4.1 实验数据集与预处理	23



4.1.1KITTI 数据集	23
4.1.2 数据预处理	24
4.2 可视化结果与分析	25
4.3 实验结果与分析	27
4.4 消融实验	28
4.5 结论	30
第五章 总结与展望	31
5.1 结论	31
5.2 展望	31
参考文献	32
致谢	34



基于深度学习的单目 3D 目标检测算法研究

摘要

在自动驾驶、机器人导航、增强现实及智能交通等领域的蓬勃发展中，3D 目标检测作为环境感知的核心技术，其重要性与日俱增。传统 3D 检测依赖激光雷达或多目视觉系统，受限于成本高昂、计算复杂及部署难度大等问题，难以在大规模实际场景中普及。单目 3D 目标检测凭借低成本、易部署的天然优势，可从单张 RGB 图像中估计目标的深度、尺寸、朝向等 3D 属性，成为学术界与工业界关注的焦点。然而，单目图像缺乏直接深度线索，导致深度估计尺度歧义、目标遮挡引发的特征混淆、背景干扰等核心挑战，严重制约检测精度与鲁棒性。

针对上述问题，本论文采用了一种基于深度学习的单目 3D 目标检测方法，核心内容包括自适应特征采样模块和物理约束数据增强方法。自适应特征采样模块基于概率采样机制与相对距离样本划分策略，通过可微分学习动态选择有效特征点，显著提高深度估计的精度和模型的鲁棒性。此外，物理约束数据增强方法模拟物理世界中物体在投影平面重叠但空间坐标不冲突的真实场景特性，通过混合同焦距图像的 3D 标注生成符合几何投影规律的增强样本。该方法避免传统增强技术（如随机旋转）破坏成像原理的缺陷，有效扩充训练数据的空间多样性，提升模型对复杂遮挡、小目标的泛化能力。

实验基于单目 3D 检测基准数据集 KITTI 展开，主要在汽车类别目标上进行全面评估。得到评估结果为：汽车类别的 3D 检测平均精度达到 26.11%，鸟瞰图平均精度达到 34.89%。这一评估结果表明，自适应特征采样模块和物理约束数据增强方法能够显著提升单目 3D 目标检测的性能，为解决单目 3D 目标检测中的深度估计不准确和数据多样性不足等问题提供了有效方案。

关键词：单目 3D 目标检测，自适应特征采样，物理约束数据增强，KITTI



Research on Monocular 3D Object Detection Algorithms Based on Deep Learning

Abstract

In the booming development of autonomous driving, robotics navigation, augmented reality, and intelligent transportation, 3D object detection, as a core technology for environmental perception, has become increasingly important. Traditional 3D detection relies on LiDAR or multi-camera vision systems, which can provide high-precision depth information but are limited by high costs, computational complexity, and deployment challenges, making them difficult to popularize in large-scale real-world scenarios. Monocular 3D object detection, with its natural advantages of low cost and easy deployment, can estimate 3D attributes (depth, size, orientation) of objects from a single RGB image, making it a focal point in both academic and industrial circles. However, the lack of direct depth cues in monocular images leads to core challenges such as depth estimation scale ambiguity, feature confusion caused by object occlusion, and background interference, severely restricting detection accuracy and robustness.

To address these issues, this paper presents a deep learning-based monocular 3D object detection method, with core components including an Adaptive Feature Sampling (AFS) module and a physical-constraint data augmentation method (SpatialMixup). The AFS module, based on a probabilistic sampling mechanism (Gumbel-Softmax) and relative distance sample partitioning strategy, dynamically selects effective feature points through differentiable learning, significantly improving depth estimation accuracy and model robustness. Additionally, the SpatialMixup method simulates real-world scenarios where objects overlap in projection but do not conflict in physical space, generating geometrically consistent augmented samples by mixing 3D annotations of co-focal images. This approach avoids the defect of traditional augmentation techniques (e.g., random rotation) that violate imaging principles, effectively expanding the spatial diversity of training data and enhancing the model's generalization ability for complex occlusions and small objects.



Experiments were conducted on the KITTI benchmark dataset for monocular 3D detection, with comprehensive evaluations performed on three object categories: Car, Cyclist, and Pedestrian. The results show that: for Cars, the Average Precision for 3D detection (AP3D) reached 26.11%, and the Average Precision for Bird's-Eye View (APBEV) reached 34.89%; for Cyclists, AP3D was 17.09% and APBEV was 25.95%; for Pedestrians, AP3D was 11.27% and APBEV was 22.59%. These findings demonstrate that the AFS module and SpatialMixup data augmentation method significantly enhance the performance of monocular 3D object detection, providing effective solutions to problems such as inaccurate depth estimation and insufficient data diversity in monocular 3D detection.

Keywords: Monocular 3D object detection, Adaptive Feature Sampling, SpatialMixup, KITTI



第一章 绪论

1.1 研究背景

在当今数字化时代，自动驾驶、机器人导航、增强现实和智能交通等领域正经历着飞速的发展，这些领域的核心需求之一是对周围环境的精确感知。3D 目标检测技术作为实现这一需求的关键技术，其重要性不言而喻。例如，在自动驾驶中，车辆需实时检测道路上的行人、其他车辆和障碍物以确保安全驾驶；在机器人导航中，机器人需识别并避开障碍物实现自主导航；在智能交通系统中，3D 目标检测可用于交通流量监测和违章行为检测，提高交通管理的效率和准确性。

传统的 3D 检测方法主要依赖于激光雷达或多目视觉系统。这些传感器能提供高精度深度信息，但同时也面临着成本高、计算复杂度高、部署困难等问题，限制了其实际场景中的应用。相比之下，单目 3D 目标检测技术作为一种低成本、高效率、易于部署的解决方案，具有显著的优势。单目 3D 目标检测仅依赖单张 RGB 图像，通过计算机视觉算法估计目标的 3D 属性，包括深度、尺寸和朝向。然而，单目图像作为 3D 场景的 2D 投影，丢失了深度维度信息，导致深度估计成为一个不适定问题（单一 2D 投影对应无穷多 3D 解）。同时，目标遮挡会导致特征缺失，背景干扰会引发特征混淆，进一步加剧深度歧义。此外，真实场景中复杂遮挡、低可见度如雨天、夜晚等情况的数据样本有限，传统数据增强方法如随机旋转容易破坏单目成像几何，导致模型泛化能力不足。

近年来，深度学习技术的突破显著推动了单目 3D 目标检测的发展。深度学习方法通过构建高效的神经网络模型，能够自动学习图像特征和深度信息，从而实现较为准确的 3D 目标定位。卷积神经网络（CNN）在图像分类和目标检测任务中取得了显著的成果。此外，多任务学习、数据增强和模型优化等技术也为提高单目 3D 目标检测的性能提供了有力支持。这些技术的发展为解决单目 3D 目标检测中的挑战提供了新的机遇。

综上所述，单目 3D 目标检测技术在自动驾驶、机器人导航、增强现实和智能交通等领域具有广泛的应用前景。然而，由于单目图像缺乏直接的深度信息，单目 3D 目标检测面临着深度估计不准确、目标遮挡和背景干扰等挑战。深度学习技术的发展为解决这些挑战提供了新的机遇。本论文旨在通过深度学习技术，使用一种高效的单目 3D 目标检测方法，以提高检测的精度和鲁棒性，推动单目 3D 目标检测技术在实际场景中的广泛应用。



1.2 国内外研究现状

1.2.1 3D 目标检测研究现状概述

3D 目标检测作为智能感知的核心技术，目前已形成三条差异化技术路线：激光雷达主导的点云方法、多目视觉主导的立体方法和单目视觉主导的轻量化方法。这些技术在硬件配置、算法原理与应用场景上各有侧重，共同推动着目标检测技术的发展。

激光雷达主导的点云方法直接获取 3D 坐标，在检测精度上占据显著优势。该类方法通过激光脉冲扫描场景获取点云数据，再利用体素化、柱体化等预处理手段将不规则点云转换为规则结构，进而采用 PointNet、PointNet++ 等网络直接提取点云特征，或借助 VoxelNet、SECOND 等框架通过 3D 卷积、稀疏卷积实现高效处理。例如，PointRCNN 通过点云语义分割与边界框优化，能够精准定位目标；SECOND 则通过稀疏卷积大幅提升计算效率，满足实时性需求。然而，这一技术路线存在明显短板：激光雷达硬件成本高昂，64 线激光雷达设备价格可达数万元，限制了其大规模应用；此外，点云在远距离场景下密度显著降低，导致小目标检测难度剧增，且数据处理对算力要求极高，进一步增加了部署成本。

多目视觉主导的立体方法基于双目或多目摄像头的视差原理，间接恢复场景深度信息。其核心流程包括相机标定、立体匹配和深度计算三个环节：首先通过张氏标定法获取相机内参和外参，确保多目图像的空间对齐；随后利用半全局匹配（SGM）或深度学习网络（如 Stereo R-CNN）计算图像间视差，并通过三角测量原理将视差转换为深度；最后结合 2D 检测框实现 3D 目标定位。在中近距离（<30 米）的纹理丰富场景中，这类方法能够达到较高检测精度。但在实际应用中，其局限性同样突出：基线长度直接影响远距深度估计精度，短基线配置会导致远距离目标深度误差急剧增大；同时，在低纹理（如白墙、水面）或反光场景下，图像特征匹配极易失效，造成深度图大面积误判，严重削弱了复杂环境下的检测稳定性。

单目视觉主导的轻量化方法以单摄像头的低成本和易部署性脱颖而出，成为边缘计算、消费级设备的较好选择。该技术路线通过“2D 图像特征+几何先验”或深度学习模型间接推断 3D 信息，例如特斯拉 FSD 系统通过时间序列分析，利用多帧图像的运动信息估计目标深度。早期方法依赖物体尺寸先验、相机成像几何约束等规则，通过数学建模恢复 3D 结构；近年来则转向端到端深度学习框架，如 SMOKE、CenterNet3D 等网络直接从 RGB 图像回归目标的 3D 属性。然而，单目视觉受限于成像原理，天然缺乏深



度信息，导致其检测精度与多传感器方案存在显著差距：深度估计依赖先验假设或学习模型，在遮挡、远距离场景下误差显著；同时，单目图像的尺度歧义问题（如近距小物体与远距大物体投影相似）增加了目标 3D 定位的难度，难以满足高精度检测需求。尽管如此，单目视觉的轻量化优势仍使其在低成本、低功耗场景中具有不可替代的价值。

1.2.2 基于单目视觉的 3D 目标检测研究现状

单目视觉技术在计算机视觉领域中为二维目标检测模型（如 R-CNN、YOLO^[1]等）提供了丰富的表观纹理与形态特征表达，显著提升了图像平面内的目标识别与定位性能。然而，当任务扩展至三维空间的目标检测时，单通道 RGB 图像因缺乏深度感知能力，难以直接从二维纹理特征推断物体在三维空间中的精确位置与姿态。为突破这一根本性局限，研究者主要采用四类技术路线：先验知识融合^[2]、几何特征提取、三维模型匹配以及单目深度估计网络，共同构建目标的立体几何表征。

早期代表性工作 Mono3D^[3]设计了两阶段检测流程：首先进行密集采样以生成多个三维候选边界框，继而通过重投影生成对应的二维检测框，利用 Faster R-CNN 网络提取视觉特征，并融合语义上下文信息、空间位置先验以及目标形状先验等多源信息，构建能量函数优化三维检测框。尽管其网络架构与 3DOP^[4]类似，采用并行分支处理候选框内部特征与周围上下文特征，但复杂的先验融合机制会导致误差累积问题，且密集采样过程会带来巨大计算开销，检测精度不突出且检测速度远不及传统二维检测器，难以满足实时检测需求。

Deep3Dbbox 方法^[5]通过扩展二维检测网络回归目标三维尺寸与航向角。该方法创新性地引入 Multi-bins 混合离散-连续回归策略处理目标航向角：将连续角度空间离散化为多个重叠区间（Multi-bins），借助卷积神经网络预测各区间置信度及角度残差修正值；目标物理尺寸则采用 L2 损失函数直接回归。该方法虽显著简化了网络结构，但因深度信息缺失，世界坐标系下的目标位置计算误差较大，尤其对小尺度目标及遮挡场景敏感。其通过最小二乘法与奇异值分解建立二维检测框与三维边界框的位置映射关系，该策略在简单场景中有效，但在复杂环境下定位精度显著下降。

深度估计的改进方案呈现多元化发展趋势：Xu 等人提出的 MF3D^[6]融合 Deep3Dbbox 框架与单目深度估计算法，通过卷积网络估计目标三维尺寸与航向角，利用子网络生成深度图并与 ROI 区域特征融合，进而计算目标在世界坐标系中的位置；Qin 等人的 MonoGRNet^[7]采用实例级深度预测机制，专注目标区域深度估计以降低计算



复杂度；Manhardt 等人的 ROI-10D^[8]结合 ResNet-FPN^[9]特征提取器与 CAD 模型匹配获取三维几何信息。另有研究基于成像几何约束推算深度，如 MonoPSR 依据相机投影模型建立物体物理尺寸与像素尺寸的比例关系，OFT-NET 则通过正交特征变换将图像特征映射至三维鸟瞰空间。单目深度估计仍面临严峻挑战：基于卷积神经网络的方法受限于训练数据质量，而几何约束方法因强假设条件难以泛化至多类别目标检测，尤其对小尺寸物体及大视野场景的适应性不足。

针对遮挡与截断目标的检测瓶颈，Chabot 等人提出的 Deep MANTA^[10]框架，该方法通过构建多任务协同学习架构，同步实现目标空间定位、三维形态估计及车辆部件识别。其技术核心在于预定义一组表征车辆外部几何结构的部件关键点，通过双级区域生成网络回归二维边界框与关键点坐标，进而与三维标准化模板库进行特征匹配，推导出精确的位姿数据。类似地，Mono3D++^[11]采用期望最大化-高斯混合（EM-Gaussian）算法补全关键点信息，结合能量函数提升检测鲁棒性；3D RCNN 则利用主成分分析（PCA）降维构建 CAD 模型基向量，实现从二维图像到三维结构的重建。此类方法虽增强了对部分遮挡的适应能力^[12]，但依赖高精度三维模板数据，且多目标检测场景下精度衰减明显，对相机坐标系下的绝对定位精度提升有限。

单目三维目标检测常采用多层级联卷积神经网络架构实现姿态参数回归，例如将目标检测网络与深度估计网络串联。然而，此类级联设计易引发误差跨层传播问题，导致三维检测精度衰减。为攻克此难题，Simonelli 等研究者^[13]提出 MonoDIS 方法，创新性地引入参数解耦机制。该方法将目标三维几何姿态建模为十维特征向量，解构成四个独立子空间：目标尺寸、深度值、航向角以及投影中心点坐标。其核心策略在于分离参数优化过程——当针对特定子空间回归计算损失函数时，其余参数固定为真实标注值。该机制显著优化了训练过程的收敛效率，有效抑制了参数间的交叉干扰。

综上分析，单目视觉三维目标检测方法可归纳为两种典型范式：第一种范式基于候选区域生成机制，通过提取潜在目标区域并融合先验知识优化三维边界框回归；第二种范式借助卷积神经网络直接学习目标三维特征表达，结合模板匹配、重投影映射及深度估计等技术实现空间位置推理。该类方法在数据获取效率与系统成本控制方面展现显著优势，然而深度感知能力的本质性缺失导致三维空间定位精度受限，特别在目标遮挡、图像截断及远距离场景下性能衰减明显。未来研究亟需突破深度推理机制创新，通过增强几何约束建模与跨模态特征融合，提升复杂场景下的检测鲁棒性，推动理论成果向实



际应用转化。

1.2.3 当前挑战与研究趋势

尽管国内外研究在单目 3D 目标检测领域取得显著进展，仍面临三方面关键挑战：其一，特征选择机制依赖启发式策略，传统方法采用固定单点或全局平均等方式聚合特征，缺乏自适应筛选能力。在复杂交通场景中，如城市街道中车辆密集、遮挡频繁，且光照条件多变，传统特征选择方法无法根据场景实时调整，导致无效特征干扰显著，如 SMOKE（2020）在遮挡场景中精度下降达 25%。其二，数据增强方法的物理一致性不足，2D 增强技术（如随机翻转）未考虑 3D 几何约束，简单的图像翻转在 3D 空间中可能导致物体形状、位置关系失真。其三，依赖深度图预处理的伪点云方法受限于边缘及远距离目标的深度估计精度，由于单目深度估计在边缘处易受图像噪声、遮挡影响，远距离目标像素分辨率低，导致深度估计误差大，这些误差在生成伪点云及后续 3D 定位过程中不断累积放大，相关改进方法通过区域金字塔与 Transformer 模块将远距离目标检测精度提升 12%，但尚未完全解决误差累积问题。

未来研究将围绕以下方向展开：动态场景建模方面，随着自动驾驶车辆在实际道路中面临大量动态目标，如行人、车辆的随机运动，结合时序信息（如视频流）捕捉目标运动轨迹成为必然趋势。通过构建基于时间序列的目标运动模型，能更好地预测目标下一时刻位置，优化动态目标的 3D 属性估计，提升遮挡场景下的检测鲁棒性。小样本学习领域，当前单目 3D 目标检测模型训练依赖大量标注数据，标注成本高昂且效率低下。探索少样本或无监督学习范式，让模型能从少量样本中快速学习目标特征，或在无标注数据下自主挖掘数据内在规律，降低对大规模标注数据的依赖，提升模型泛化能力，将是突破当前数据瓶颈的关键。轻量化部署方向，自动驾驶对计算资源和实时性要求极高，现有模型在精度提升的同时往往带来计算复杂度剧增的问题。设计高效网络架构，在保持精度的同时降低计算复杂度，如采用模型剪枝、量化技术，将模型压缩至可在车载计算平台实时运行，满足自动驾驶等实时性要求高的应用场景需求。这些方向的突破将推动单目 3D 目标检测技术向更鲁棒、更高效的方向发展。

1.3 论文的主要研究内容与章节安排

本文围绕单目 3D 目标检测技术展开，重点探讨了基于深度学习的单目 3D 检测方法，内容主要集中在两个方面：一是引入一种基于深度学习的自适应特征采样（AFS）模块，旨在从图像特征中自适应地选择对 3D 属性学习最有价值的样本；二是使用一种



物理约束的数据增强方法 SpatialMixup，用于扩充训练数据集，同时保持图像的物理一致性和目标物体的空间关系。通过这两个方法提高单目 3D 目标检测的精度和鲁棒性，为自动驾驶场景中的目标检测提供更可靠的解决方案。论文的主要内容与章节安排如下：

第一章：绪论。介绍单目 3D 目标检测技术的研究背景和意义，阐述当前自动驾驶领域对 3D 目标检测技术的需求以及单目相机相较于其他传感器的优势。接着，对 3D 目标检测技术的国内外研究现状进行全面梳理，包括 3D 目标检测的总体研究进展、基于单目视觉的 3D 目标检测方法、以及其他相关技术的发展现状，并分析当前该领域面临的挑战与未来的研究趋势。最后，概述本文的主要内容，并对论文的章节结构进行了简要介绍。

第二章：深度学习理论基础。本章为后续方法奠定了理论基础，详细介绍了深度学习中的卷积神经网络（CNN）及其关键组件，包括卷积层、池化层、激活函数和全连接层。进一步探讨了目标检测算法的基础知识，区分了两阶段检测算法和单阶段检测算法的特点与原理，并对单目 3D 目标检测方法进行了概述，为后续章节中的改进方法提供了必要的背景信息。

第三章：基于样本选择的单目三维目标检测方法。本章是论文的核心部分，系统地阐述了基于 MonoSelect3D 的单目 3D 检测方法。首先，对 MonoSelect3D 的整体架构进行了介绍，接着深入探讨了自适应特征采样（AFS）模块的设计与实现，包括基于 Gumbel-Softmax 的概率采样和相对距离样本划分策略。此外，详细介绍了损失函数和训练策略，并使用了物理约束数据增强方法 SpatialMixup，旨在提升模型的泛化能力和对 3D 属性的鲁棒性。

第四章：实验结果与分析。在本章中，对 MonoSelect3D 方法进行了全面的实验验证。首先介绍了数据集，包括数据集内容、评估指标、数据集划分。接着介绍预处理，包括数据清洗，归一化，物理约束增强，和训练流程等关键细节。然后，展示了实验结果。通过消融实验验证了各个模块对模型性能的贡献。

第五章：总结与展望。本章对全文的工作进行了总结，概括了基于 MonoSelect3D 的单目 3D 检测方法的主要成果，包括技术贡献、实验验证和创新点。同时也对未来单目 3D 目标检测技术的发展方向进行了展望，提出了可能的研究方向和改进建议，为后续研究提供了参考和启发。

第二章 深度学习理论基础

2.1 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）作为深度学习的核心架构，专精于处理网格化结构数据。该网络通过卷积运算捕获图像的局部空间特征（如边缘纹理），在单目三维目标检测任务中，能够从 RGB 输入生成多尺度特征表达，为深度估计与三维边界框预测奠定基础。典型架构如 ResNet 和 DLA34，借助深层特征聚合机制增强语义表征能力，显著提升目标物体的理解精度与空间定位性能。Le Net 模型作为一种经典的 CNN 架构，展示了 CNN 的基本结构，其结构如图 2.1 所示，包括卷积层、池化层、激活函数和全连接层等关键组件，这些组件的协同作用，使得 CNN 在处理图像数据时能够逐层提取更高级的特征表示。这种分层次的特征提取能力，是 CNN 在众多图像处理任务中取得成功的关键因素之一。




图 2.1 Le Net 模型结构

2.1.1 卷积层

卷积层作为卷积神经网络（CNN）的核心构成单元，其核心功能是通过卷积运算实现对输入数据的特征提取。该层由若干卷积核组成，每个卷积核在输入特征图上按设定步长滑动，通过元素级乘积与累加操作生成对应的输出特征图。卷积核尺寸与步长是卷积层的两个关键参数：前者决定了模型的感受野范围，后者则控制卷积核在特征图上的移动步幅。

卷积操作是一种高效的图像特征提取机制，通常采用正方形卷积核逐像素遍历输入图像。具体计算过程为：在图像与卷积核的重叠区域内，将每个对应位置的像素值与卷积核权重相乘后求和，再加上偏置项，最终得到输出特征图中的一个像素值。这种基于局部感知和权重共享的运算模式，使得卷积层能够有效捕捉图像中的空间层次特征，成为深度学习视觉任务的基础组件。图 2.2 为卷积计算示意图。




图 2.2 卷积计算示意图

在图 2.2 所示的卷积运算示例中，输入为 5×5 矩阵，采用 3×3 的卷积核进行处理。根据公式 2-1 和公式 2-2 计算卷积后的特征图的大小为 3×3 。

$$W_{output} = \frac{W_{input} - W_{filter} + 2P}{S} + 1 \quad (2-1)$$

$$H_{output} = \frac{H_{input} - H_{filter} + 2P}{S} + 1 \quad (2-2)$$

式中 P 为填充宽度， S 为步长，即卷积核一次移动的长度。如公式 2-3 所示为卷积的线性运算。

$$y_{mn} = \sum_{j=0}^{J-1} \sum_{i=0}^{I-1} x_{m+i, n+j} w_{i,j} + b \quad (0 \leq m \leq M, 0 \leq n \leq N) \quad (2-3)$$

式中 w 为大小 $J \times I$ 的卷积核矩阵， b 为偏置项。 x 为 $M \times N$ 的二维输入矩阵， y 是输出特征图。该运算通过卷积核与输入矩阵的局部区域进行元素级乘积求和，并叠加偏置，实现特征提取与变换。

2.1.2 池化层

在卷积层内，通过调整步长参数 s 可使特征图空间尺寸的倍率缩减，有效降低网络参数量。除步长调控外，还存在一类专门用于实现尺寸缩减的网络层：池化层。池化层基于局部相关性原理，通过对局部相关元素组进行信息采样或聚合，生成新的特征响应

值。其核心作用在于压缩特征图的空间维度，减少计算复杂度，同时提升模型对输入平移的鲁棒性。常见的池化操作有两种：最大池化（Max Pooling）提取局部区域内最大值作为输出；平均池化（Average Pooling）则通过计算局部元素的特征均值生成结果。池化操作示意图如图 2.3 所示。




图 2.3 池化操作示意图

2.1.3 激活函数

神经网络中信息流遵循层级传递原则：每个神经元接收前层神经元的输出信号作为输入，经处理后向后续层级传递。输入层神经元直接将原始属性值传递至隐藏层或输出层。在多层网络结构中，相邻层级间的数据变换由激活函数（Activation Function）定义。若取消激活函数，每层节点的输入仅为上层输出的线性组合，理论分析表明，无论网络层数多少，最终输出均为输入特征的线性叠加，等效于无隐藏层的感知机模型。这种结构导致网络逼近能力严重受限。因此，引入非线性激活函数是提升深层神经网络表征能力的关键，使网络能够学习和拟合复杂的非线性映射关系，从而突破线性模型的功能瓶颈。

Sigmoid 函数常用的非线性的激活函数，其数学表达式如公式 2-4 所示。

$$f(z) = \frac{1}{1+e^{-z}} \quad (2-4)$$

Sigmoid 函数将输入的连续实数值映射至 (0,1) 区间，然而当输入值的绝对值较大时，其导数会趋近于零，从而在单目三维检测任务中引发梯度退化现象，尤其对远距离目标的深度回归过程产生不利影响。此外，该函数涉及幂运算，在计算实现时复杂度较高，在大型网络训练过程中将产生较高的计算开销。

相较于 Sigmoid 函数，ReLU 激活函数在计算效率与梯度特性上表现出明显优势。

其通过符号判断操作（输入大于 0 时直接输出原值，否则输出 0）实现快速计算，有效提升网络收敛速度，同时在正输入区间避免了梯度消失问题。Relu 函数的解析式如公式 2-5 所示。

$$\text{Relu} = \max(0, x) \quad (2-5)$$

2.1.4 全连接层

全连接层通常位于网络结构的末端，每个节点均与前一层全部节点建立完全连接，旨在将卷积层、池化层等前序层级提取的局部特征映射至样本标记空间，以实现分类或回归任务。该层的核心功能体现在两方面：首先，通过整合前层特征表示形成统一的特征向量，消除特征空间位置信息对分类决策的影响，从而增强模型的空间不变性；其次，该层实质上构建了从特征空间到标签空间的非线性映射函数，兼具特征整合与分类决策的双重作用，通过密集连接机制将分层提取的语义特征映射到目标任务空间。这种结构设计显著提升了网络对输入数据空间变换的鲁棒性。全连接层示意图如图 2.4 所示。




图 2.4 全连接示意图

图 2.4 中的 x_1, x_2, x_3 为全连接层的输入， a_1, a_2, a_3 为输出。对应的数学关系如公式 2-6 所示。

$$\begin{aligned} a_1 &= w_{11} * x_1 + w_{12} * x_2 + w_{13} * x_3 + b_1 \\ a_2 &= w_{21} * x_1 + w_{22} * x_2 + w_{23} * x_3 + b_2 \\ a_3 &= w_{31} * x_1 + w_{32} * x_2 + w_{33} * x_3 + b_3 \end{aligned} \quad (2-6)$$

式中 w 即为在模型训练中更新的参数，也为全连接中对于每个输入所对应的权重。



2.1.5 损失函数

损失函数是卷积神经网络训练过程中的关键组件，用于量化模型预测输出与真实标签之间的差异。通过最小化损失函数，模型能够迭代调整参数以提升预测精度。损失函数的选择和设计直接影响模型的性能和收敛效率。

在卷积神经网络（CNN）中，损失函数通常与末端的全连接层关联，全连接层负责将特征空间映射至样本标记空间，而损失函数则基于该映射结果计算预测误差。常见的损失函数包括均方误差（Mean Squared Error, MSE）、交叉熵损失（Cross-Entropy Loss）等。

均方误差是回归任务中常用的损失函数，通过计算预测值与真实值的平均平方差来衡量误差其数学表达式如公式 2-7 所示。

$$L = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2-7)$$

式中， y_i 是真实值， $\hat{y}_i$ 是预测值， N 是样本数量。由于误差项的平方运算，该损失函数对均方误差对较大的误差更为敏感，较大预测偏差更为敏感，促使模型在训练中优先关注显著偏离的样本。

交叉熵损失则广泛应用于分类任务，用于衡量模型预测概率分布与真实概率分布之间的差异。对于二分类任务，交叉熵损失的数学表达式如公式 2-8 所示。

$$L = -(y \log \hat{y} + (1 - y) \log (1 - \hat{y})) \quad (2-8)$$

对于多分类任务，交叉熵损失通常与 softmax 函数结合使用，其数学表达式如公式 2-9 所示。

$$L_{CE} = - \sum_{i=1}^C y_i \log \hat{y}_i \quad (2-9)$$

式中， y_i 是真实标签的独热编码， $\hat{y}_i$ 是模型预测的概率分布， C 是类别数量。交叉熵损失能够有效指导模型学习类别之间的区分特征，提高分类的准确性。

在单目 3D 目标检测中，损失函数的设计需要综合考虑目标物体的 2D 位置、类别以及 3D 属性（如深度、尺寸、方向）的预测。多任务学习场景下，通常会结合多种损失函数，对不同任务的损失进行加权求和，以平衡各个任务的学习进度和影响。通过合理选择和设计损失函数，可以有效引导模型学习到数据中的复杂模式，提高模型在特定任务上的性能。损失函数不仅反映模型的预测误差，还为模型优化提供方向，是神经网络训练过程中不可或缺的一部分。



2.2 目标检测算法基础

作为计算机视觉领域的核心技术之一，目标检测致力于同时完成图像中的目标物体进行精准定位与类别判定。区别于仅需判断图像中目标存在性的图像分类任务，目标检测不仅需要判断物体类别，还需生成表征目标空间范围的边界框（bounding box），其通过四元坐标参数（ $x_{\min}$, $y_{\min}$, $x_{\max}$, $y_{\max}$ ）精确定位目标在图像平面内的位置区域。此项技术在智能交通管理、安防监控等场景具有重要应用价值，例如实时追踪道路车辆与行人动态，或识别监控画面中的异常行为。

目标检测算法主要分为单阶段（如 YOLO、CenterNet）和两阶段（如 Faster R-CNN）两大类。在单目三维目标检测任务中，单阶段算法凭借高效特性更适配实时应用需求，以 CenterNet 为例，其通过关键点估计简化 2D 检测过程，为 3D 属性预测提供优质输入。但两阶段算法在复杂场景中的精度优势，使其在多模态融合任务中仍被广泛采用。两类框架在精度与效率间的平衡，推动了检测技术的进步，为单目 3D 检测奠定了基础框架。

2.2.1 双阶段检测算法

两阶段检测算法的典型代表是 R-CNN^[14] 系列算法，如 Fast R-CNN^[15]、Faster R-CNN^[16] 等。这类算法的核心思想是将目标检测任务划分为两个阶段：候选区域提取和区域分类及定位回归。第一阶段，算法通过特定的区域提议机制生成潜在目标区域。例如，在 Faster R-CNN 引入的区域提议网络（Region Proposal Network, RPN）能够基于输入图像特征快速生成大量不同尺度和位置的候选区域。RPN 通过卷积神经网络提取图像特征，在特征图上采用滑动窗口策略生成多尺度、多长宽比的候选框，以覆盖图像中可能存在的各类目标。

第二阶段针对生成的候选区域进行分类和精确定位。将候选区域输入卷积神经网络进行特征提取，通过深度卷积操作生成表征候选区域的特征向量。基于这些特征，分类器判别候选区域的目标类别，回归模型则优化候选区域的位置坐标，从而得到更精准的边界框。以 Fast R-CNN 为例，其损失函数融合了分类损失与回归损失，通过联合训练机制使网络同时学习目标类别的判别特征和边界框的位置偏差。其损失构成如公式 2-10 所示。

$$L = L_{\text{cls}} + L_{\text{reg}} \quad (2-10)$$

式中， L_{cls} 表示分类损失，通常采用交叉熵损失函数，用于衡量预测类别与真实类



别之间的差异； L_{reg} 表示回归损失，通常采用 Smooth L1 损失函数，用于衡量预测边界框与真实边界框之间的位置偏差。通过最小化损失函数，网络能够不断优化自身的参数，从而提高目标检测的精度。

两阶段算法在复杂场景和小目标检测中优势显著，通过对每个候选区域独立进行特征分析和参数回归，能够充分挖掘目标细节信息，实现高精度检测。然而，分阶段处理模式导致算法计算复杂度提升，检测效率下降，因此更适用于对精度要求较高但实时性要求较低的场景，如安防监控中的图像精细分析、医学影像的病灶检测等领域。

2.2.2 单阶段检测算法

YOLO (You Only Look Once) [17]与 SSD (Single Shot Multibox Detector) [18]是单阶段目标检测算法的典型范例。这类算法的核心设计理念是将目标检测转化为端到端的回归任务，通过单一网络架构同步实现目标分类与定位。以 YOLO 为例，其采用全卷积网络 (Fully Convolutional Network, FCN) 架构，对输入图像进行全局处理，直接输出图像中各目标的类别概率与边界框坐标。具体而言，YOLO 将输入图像划分为若干固定尺寸的网格单元 (grid cell)，每个网格单元负责预测若干边界框 (bounding box) 及其对应的类别概率。边界框以相对于网格单元的位置坐标、宽度及高度进行表征，类别概率则反映该边界框包含目标的置信度及目标类别的条件概率。网络通过在末端层叠加多个卷积层与全连接层，实现边界框参数与类别概率的联合预测，从而在单次前向传播中完成目标检测的核心任务。

SSD 算法在 YOLO 框架的基础上提出改进方案，通过多尺度特征图实施预测机制，实现对不同尺寸目标物体的有效检测。该算法于特征提取网络的多个中间层级附加预测模块，这些中间层生成的特征图具备差异化的分辨率与语义信息：高分辨率特征图因蕴含丰富的局部细节特征，能够对较小目标物体进行检测；低分辨率特征图则凭借更强的语义抽象能力和全局感知范围，适用于较大目标物体的识别。通过对多尺度特征图的信息融合，SSD 算法构建了针对不同尺度目标物体的全方位检测体系，显著提升了检测算法在复杂场景下的泛化性能。

单阶段目标检测算法凭借处理速度快、效率高的特性，能够在维持一定检测精度的同时实现目标的快速检测，使其在对实时性要求较高的场景（如自动驾驶、实时视频监控等）中具有显著优势。然而，由于该类算法通常采用端到端的直接处理模式，在小目标或复杂场景下的检测精度往往低于两阶段算法。究其原因，小目标在图像中占据的像



素区域有限，特征表征较为薄弱，易受背景噪声干扰；而复杂场景中目标的形状、姿态及尺度变化较大，增加了检测难度。在此类情形下，单阶段算法可能难以精准区分目标与背景，进而导致检测精度下降。

在单目三维目标检测领域，算法设计通常基于二维目标检测框架，并在此基础上拓展对目标深度、尺寸及方向等三维属性的预测功能。以自动驾驶场景为例，单目视觉不仅需要确定道路上车辆、行人的二维图像位置，还需估计其深度信息（与摄像头的距离）、三维尺寸（高度、宽度、长度）及方向角（相对于摄像头的朝向），这些参数对路径规划、碰撞预警等任务至关重要。

单目三维目标检测算法常通过改进二维检测模型实现功能扩展。例如，CenterNet算法通过关键点估计优化二维检测流程，提升了检测速度与精度。在三维检测中，研究者借鉴其思路，将目标中心点作为关键特征点，在检测中心位置的基础上预测三维属性。具体流程为：首先利用 CenterNet 对输入图像进行关键点检测，定位目标中心；然后以中心点为基准，在特征图中提取目标区域特征，并输入至三维属性预测网络。该网络通常采用多分支结构，分别处理深度、尺寸和方向角预测任务：深度信息通过回归模型直接输出距离值；三维尺寸结合图像投影特征与先验知识（如物体平均尺寸）进行估计；方向角则通过多分类（离散区间划分）或连续回归方法预测。

此外，部分算法尝试融合多阶段处理流程，结合单阶段与两阶段算法的优势：第一阶段利用单阶段算法快速生成粗略候选区域，第二阶段对候选区域进行精细化三维属性预测与分类。这种方法在保证实时性的同时提升检测精度，尤其适用于复杂场景和小目标检测。然而，多阶段设计会增加算法复杂度与计算量，需在精度与速度间进行合理权衡。

第三章 基于样本选择的单目三维目标检测方法

3.1 基于样本选择的单目方法详述

基于单目视觉的三维目标检测技术旨在从单张 RGB 图像中推断物体的类别及其 3D 边界框参数，具体包含 3D 中心坐标(x,y,z)、几何尺寸(h,w,l)及偏航角 θ 然而，由于传统方法无法有效区分训练集中的正负样本，导致模型易被负样本误导，无法准确估计目标物体的深度信息。针对此问题，本论文采用基于样本选择（MonoSelect3D）的单目三维方法，通过自适应的特征选择机制提升三维检测精度。

MonoSelect3D 架构是一种先进的单目 3D 目标检测方法，它通过引入自适应样本选择机制突破了传统固定特征选择方法的局限（如 SMOKE 的单一关键点估计），显著提升了检测精度。MonoSelect3D 框架主要包括 2D 探测器、区域特征对齐模块（Region Feature Aligner）、3D 检测头和自适应采样特征模块（Adaptive Feature Sampler）。其整体架构如图 3.1 所示。




图 3.1 MonoSelect3D 框架

本框架以改进的 CenterNet^[19]为基础构建 2D 检测主干网络，能高效地从输入图像中提取目标的 2D 特征，并生成初步的 2D 检测结果。这些结果包括 2D 边界框和目标类别，为后续的 3D 属性预测提供了基础。它以图像 $I \in \mathbb{R}^{H \times W \times 3}$ 作为输入，采用 DLA34 特征提取器^[20]对输入图像进行多尺度特征提取，生成具有空间信息的深度特征 $F \in \mathbb{R}^{\frac{H}{4} \times \frac{W}{4} \times C}$ ，其中



C 是通道数。深度特征 F 输入到三个 2D 检测头中，通过并行预测分支分别输出 2D 边界框偏移量、目标尺寸及 2D 热力图信息，进而综合这些预测结果生成包含 2D 边界框与类别标签的初步检测输出，为后续 3D 属性预测提供基础定位信息。

区域特征对齐模块（Region Feature Aligner）基于 2D 检测结果从深度特征图 F 中针对 n 个感兴趣区域（ROIs）提取目标特征，输出尺寸为 $d \times d$ 的特征矩阵。该模块通过裁剪与对齐操作，对特征图进行精细化处理以满足后续模块的输入要求。具体而言，Region Feature Aligner 采用双线性插值算法对特征图进行精细化采样，保留目标区域的特征信息，适应后续网络层的要求。与传统 ROI-Pooling 方法相比，Region Feature Aligner 能够更精确地对齐目标区域的特征坐标，有效规避量化误差对特征完整性的影响，为 3D 检测头提供高分辨率的目标特征输入。这种设计在保留目标细节信息的同时，提升了特征表示的空间对齐精度，为后续 3D 几何参数预测奠定了坚实基础。

MonoSelect3D 通过多节点并行回归策略突破传统单阶段方法的局限性，该策略不同于常规基于单一特征点预测 3D 边界框的方式，而是利用目标特征中的多个采样点并行预测 3D 边界框参数及对数概率分布。通过聚合多点特征信息，该策略显著增强了深度估计的稳定性，尤其在遮挡场景中能够聚焦未被遮挡的有效区域。3D 检测头由多个独立预测分支构成，分别负责不同 3D 属性的预测，包括深度、尺寸、方向以及 3D 中心点在图像平面上的投影偏移。每个预测头都拥有独立的网络结构，能够专注于特定的 3D 属性预测，进而提高预测精度。其中，深度预测头负责估计目标的深度信息，为 3D 定位提供关键依据；尺寸预测头专注于预测目标的 3D 尺寸，即高度、宽度和长度；方向预测头则采用多区间（bin）设计来估计目标的方向角，通过区间分类结合残差修正提升角度预测精度；而投影偏移预测头的作用是修正 3D 中心点在图像平面上的投影位置，从而提高 3D 定位的精度。这些预测头协同工作，确保了目标物体完整 3D 信息的准确构建。此外，深度不确定性估计沿用 GUPNet^[21]的多 Bin 设计，输出深度值、深度方差及分类对数概率图的多维参数。

作为本框架的核心组件，自适应采样特征（AFS）模块通过概率扰动的自适应选择（Gumbel-Softmax）方法和相对距离样本划分策略，实现 3D 属性学习的动态特征筛选。具体而言，AFS 模块首先运用 Gumbel-Softmax 概率重参数化对特征点的 logits 进行处理，通过对数概率扰动与温度缩放，将离散采样过程转化为可微分的连续概率分布，保证梯度反向传播的有效性以支持端到端训练。接着，通过相对距离样本划分策略，计算特征



点之间的相对距离，区分正负样本，过滤掉遮挡场景中的误导性背景特征。克服固定阈值策略在遮挡场景下的局限性。最终，AFS 模块生成采样图，指导网络专注于对 3D 检测真正有价值的特征，进而增强模型对目标三维特性的判别能力。

通过 2D 检测、特征对齐、多属性预测头及 AFS 模块的等各模块的协同工作，MonoSelect3D 方法在单目 3D 目标检测任务中实现了高精度的检测性能。MonoSelect3D 在 KITTI 等基准数据集上展现出卓越的 3D 检测性能。实验结果表明，该框架在无需额外传感器数据的条件下，有效解决了单目视觉中深度模糊、遮挡干扰等关键问题，为自动驾驶环境感知提供了可靠的纯视觉解决方案。

3.2 物理约束数据增强方法

在单目 3D 目标检测任务中，数据增强技术的设计需严格遵循成像几何约束。传统数据增强方法例如随机裁剪、缩放或视角变换，常因破坏投影一致性而导致 3D 属性学习偏差，此外，现有的全局像素混合策略如传统 MixUp 难以适配单目检测中局部特征敏感的建模需求。为此，本工作采用物理约束数据混合增强（SpatialMixup）方法，通过建立多层次几何约束条件，在目标级特征空间中模拟物理遮挡现象，同时确保增强样本的投影合理性。

SpatialMixup 方法在传统 2D MixUp 的基础上引入多视几何一致性约束，使生成图像符合空间重叠的物理成像原理。该方法将不同图像中的检测目标按照一定比例混合，同时施加几何约束以保持成像一致性，从而生成具有空间重叠的图像样本。这种方式能够在不引入歧义的情况下，有效地丰富训练数据，提升模型对 3D 属性的感知能力。

传统的样本方法在 2D 像素坐标系统中按比例混合不同的图像，而忽视了 3D 投影几何的物理约束，此类操作可能引发多重成像矛盾。例如，不同焦距或分辨率的图像混合会引发深度歧义，破坏像素坐标与 3D 深度的比例关系，导致目标尺寸估计偏差；再比如，不同视角拍摄的图像混合会破坏物体的空间投影一致性。这些几何矛盾使得增强样本的物理合理性无法保障，进而干扰模型对 3D 属性的学习。为此，本方法使用几何约束混合策略，对要混合的图像施加约束，以确保它们具有相同的焦距、主点、分辨率和相机视图（俯仰和翻滚角度），在此约束下，不同时空捕获的图像可等效视为同一相机在同一视角下的观测结果。在实际应用中车载相机的刚性安装特性（固定内参、水平视角）天然满足上述约束条件，故算法仅需简单的焦距分组预处理确保图像的焦距相同即可。该设计在保证几何合理性的同时大幅降低计算复杂度，为实际部署提供便利。

训练数据集 $I = \{I_{f_1}, I_{f_2}, \dots, I_{f_K}\}$, 其中 I_{f_k} 对于 $k \in [1, K]$ 意味着 I_{f_k} 中的图像具有相同的焦距 f_{k_t} 。将图像和相应的标签表示为 $I_{f_k} = \{(x_1^{f_k}, y_1^{f_k}), (x_2^{f_k}, y_2^{f_k}), \dots, (x_N^{f_k}, y_N^{f_k})\}$, 总共有 N 个样本。SpatialMixup 过程定义如公式 3-1 所示。

$$\begin{cases} x_n^{f_k} = \lambda \cdot x_n^{f_k} + (1 - \lambda) \cdot x_m^{f_k} \\ y_n^{f_k} = y_n^{f_k} + y_m^{f_k} \end{cases} \quad (3-1)$$

式中 $n, m \in [1, N]$ 且 $n \neq m$, λ 表示混合比例。

3.3 自适应特征采样模块

自适应特征采样模块 (Adaptive Feature Sampler, AFS) 作为 MonoSelect3D 框架的核心组件, 旨在从目标物体的特征图中动态筛选出对 3D 属性最具判别性的局部区域。其核心思想是借助学习机制, 自适应地精确识别并聚焦于那些对 3D 检测有价值的特征, 同时过滤掉不相关或具有误导性的特征。该模块主要由基于概率扰动的自适应采样方法 (Gumbel-Softmax) 和相对距离样本分割器协同工作, 有效提升目标 3D 属性预测的特征质量。AFS 模块的示意图如图 3.2 所示。




图 3.2 自适应特征采样模块



3.3.1 基于概率扰动的自适应样本选择机制

为实现特征样本的动态筛选，本方法引入基于概率扰动的自适应选择机制：Gumbel-Softmax 概率采样。具体而言，对于均匀分布随机变量 $U \sim \text{Uniform}(0,1)$ ，通过逆变换采样生成 Gumbel 分布随机变量 G ，其表达式如公式 3-2 所示。

$$G = -\log(-\log(U)) \quad (3-2)$$

Gumbel-Max 方法^[22]通过对对数概率施加 Gumbel 分布进行扰动，并结合 argmax 函数实现离散采样，实现了非随机的概率采样，基于这一方法，Gumbel-Softmax^[23]采用 softmax 函数作为 argmax 的连续可微近似，实现了整体的可微性。Gumbel-Top-k^[24]通过无放回地抽取大小为 k 的有序样本，将采样点的数量从单一的 Top-1 扩展到 Top-k，其中 k 是一个超参数。然而，相同的 k 并不适合所有目标，例如，被遮挡的目标应该比正常目标具有更少的正样本。为此，本方法采用了一个基于相对距离的无超参数模块，以自适应地划分样本。

AFS 模块利用 Gumbel-Softmax 方法，通过向特征点的对数概率添加 Gumbel 噪声并应用 softmax 函数，将离散的特征点采样过程转化为可导的连续过程。这种方法确保了端到端训练的有效性，特别适合单目 3D 检测中特征选择的高度动态性，例如在遮挡场景下自适应聚焦于高置信度区域。假设 $\Phi = \{\phi_1, \phi_2, \dots, \phi_N\}$ 为模型输出的对数概率分布图，其中 $N=d \times d$ 表示采样点的数量。每个元素 $\phi_i (i \in [1, N])$ 表示一个对数概率。对图 Φ 执行 Gumbel-Softmax 操作以实现概率采样。具体来说，首先根据上述描述生成一个大小为 $d \times d$ 的 Gumbel 分布 G ，并将其添加到 logit 图 Φ 中，其过程如公式 3-3 所示，得到经过 Gumbel 噪声扰动后的对数概率图，对数概率图中内容如公式 3-4 所示。

$$\hat{\Phi} = (G + \Phi) \quad (3-3)$$

$$\text{logit}\hat{\Phi} = \{\hat{\phi}_1, \hat{\phi}_2, \dots, \hat{\phi}_N\} \quad (3-4)$$

通过这种方式，原本较低的对数概率值有机会超过其他较高的对数概率值。然后，采用温度缩放的 softmax 函数处理 $\hat{\Phi}$ ，其过程如公式 3-5 所示，得到连续概率分布图 S ，连续概率分布图中内容如公式 3-6 所示。

$$S_i = \frac{\exp(\hat{\phi}_i/\tau)}{\sum_{j=1}^N \exp(\hat{\phi}_j/\tau)} \text{ for } i = 1, \dots, N \quad (3-5)$$

$$S = \{S_1, S_2, \dots, S_N\} \quad (3-6)$$

式 3-3 中， G 是生成的 Gumbel 噪声， Φ 是输入的 logits，式 3-6 中， τ 是温度系数，在本工作中设置为 1，用于控制输出分布的离散程度。

3.3.2 相对距离样本划分策略

AFS 模块采用相对距离样本划分策略来代替 Gumbel-Top-k 中的固定 k ，以实现自适应样本分配，有效区分正负样本。通过计算特征点之间的相对距离，可以更有效地适应不同目标的特征分布情况。具体而言，对于排序后的 softmax 概率向量，通过计算相邻元素间的相对距离确定最优划分阈值，避免了绝对距离因 softmax 函数指数放大效应导致的正样本数量不足问题。以输入向量 $[20, 18, 17, 7]$ 为例，其 softmax 输出为 $[0.84, 0.12, 0.04, 0]$ ，若采用绝对距离划分仅能得到一个正样本，而相对距离方法可识别出三个有效正样本，显著提升了遮挡场景下的特征利用率。

具体实现流程如下：首先，将连续概率分布图 S 展平为一维向量 $\text{Soft } S$ 按降序排列，得到排序后的向量 $\text{Sort } S$ ；继而根据公式 3-7 计算排序后的向量 $\text{Sort } S$ 中相邻元素的相对距离。

$$\begin{aligned} Dis_{S_i} &= \frac{Sort_{S_i}}{Sort_{S_{i+1}}} = \frac{\exp(\hat{\phi}_{f(i)}/\tau)}{\exp(\hat{\phi}_{f(i+1)}/\tau)} \\ &= \exp\left(\frac{\hat{\phi}_{f(i)} - \hat{\phi}_{f(i+1)}}{\tau}\right) \text{for } i = 1, \dots, N-1 \end{aligned} \quad (3-7)$$

式中， $f(\cdot)$ 表示从排序向量到原概率分布的映射关系。假设 Dis_{S_i} 是 Dis_S 中的最大值，由于指数函数的单调递增特性，因此 $\hat{\phi}_{f(i)} - \hat{\phi}_{f(i+1)}$ 是 $\hat{\Phi}$ 中的最大间隔。采用相对距离本质上是在寻找经过 Gumbel 分布调整的概率分布中最具区分性的值，以区分正样本和负样本。将与最大值 Dis_{S_i} 对应的向量 $Sort_{S_i}$ 作为阈值来过滤负样本。具体来说，将连续概率分布图 S 中小于最大值对应 $Sort_{S_i}$ 的值设置为 0，得到最终的采样图 $\text{Sample } S$ 。基于上述设计，AFS 模块实现了无超参数的可微动态样本分配。

3.4 损失函数和训练策略

在目标检测模型的训练过程中，损失函数的设计对于模型的性能至关重要。合理的损失函数能有效引导模型学习目标物体的特征信息并准确预测其类别与位置。本方法中，总损失 L 采用分层监督机制，由 2D 损失和 3D 损失组成，其构成如公式 3-8 所示。

$$L = L_{2d} + L_{03d} + (L_{S3d} + L_{depth} + L_{\theta}) \cdot \text{Sample}_S \quad (3-8)$$



式中， L_{S3d} 为尺寸预测的 L1 损失， L_{O3d} 为 3D 中心投影偏移的 Smooth-L1 损失。 L_{depth} 为深度损失， L_{θ} 为方向损失。

2D 损失 L_{2D} 遵循 CenterNet^[19] 的设计，3D 损失采用基于 AFS 模块的多任务损失函数来监督 3D 属性的学习，包括尺寸预测损失 L_{S3D} 、深度损失 L_{depth} 和方向损失 L_{θ} 。将总损失分为 2D 损失和 3D 损失，源于目标检测任务需同时关注目标物体在 2D 图像平面和 3D 空间中的特性。2D 损失负责监督目标在图像中的位置与类别学习，3D 损失则引导模型预测深度、尺寸和方向等 3D 信息，从而在保证 2D 定位精度的基础上提升 3D 属性预测能力。

2D 损失沿用 CenterNet 的设计，该模型作为基于关键点估计的单阶段目标检测算法，通过预测目标物体中心点热图、边界框偏移量和尺寸等信息实现高效目标检测。其损失函数经实践验证能够有效指导模型学习目标物体在 2D 图像中的特征表示。相比其他 2D 目标检测算法，CenterNet 在速度和精度方面取得良好平衡，适配实时应用场景，故本方法以其损失函数作为 2D 损失基础，确保模型在 2D 检测任务中的鲁棒性与高效性。3D 损失采用基于 AFS 模块的多任务损失函数，因为 AFS 模块能自适应地选择对 3D 属性学习最具价值的样本，而多任务损失函数综合考虑目标物体的深度、尺寸和方向等多个属性，使模型在学习过程中平衡不同属性的预测精度通过同时优化相关任务充分利用数据信息，提升泛化能力与学习效率，实现对目标 3D 信息的准确预测。具体而言，尺寸预测损失 L_{S3D} 采用 L1 损失函数，计算方法如公式 3-9 所示，用于衡量预测的 3D 尺寸与真实值之间的差异。其对异常值的鲁棒性可有效引导模型学习目标准确尺寸。

$$L_{S3D} = \frac{1}{N} \sum_{i=1}^N \left\| \hat{w}_i \hat{h}_i \hat{l}_i - w_i h_i l_i \right\|_1 \quad (3-9)$$

深度损失 L_{depth} 采用拉普拉斯不确定性损失 [5, 18]，该损失函数可同时预测深度值及其不确定性，通过最小化预测深度和真实深度之间的差异以及不确定性估计来提升深度预测的准确性；其计算方法如公式 3-10 所示。

$$L_{depth} = \frac{1}{2\sigma^2} \sum_{i=1}^N \left\| \hat{d}_i - d_i \right\|_1 + \log(\sigma) \quad (3-10)$$

方向损失 L_{θ} 采用多区间设计，将方向角划分为多个区间，在各区间内进行回归预测，有效应对方向角的周期性与离散性问题，提高方向预测精度。



在计算各属性损失之后，将尺寸、深度和方向属性的损失图与 AFS 模块生成的最终采样图 **Sample S** 相乘，以抑制负样本的损失反向传播，使模型聚焦于对 3D 检测有价值的正样本特征，避免负样本干扰。AFS 模块通过自适应地选择正样本，动态调整特征采样过程，助力模型在不同场景下有效地学习目标物体的 3D 属性。

在训练策略方面，为减少训练过程中的不稳定性，采用 HTL^[25] (Hierarchical Training Loss) 训练策略，通过逐步引入不同层次的损失函数，使模型平稳学习目标物体特征。此外，鉴于 3D 属性损失的不稳定性可能干扰正样本点选择，在训练 AFS 模块时使用预热策略：训练早期使用所有样本学习 3D 属性，直至深度损失稳定。深度是影响 3D 边界框准确性的核心属性，其损失的稳定是启动 AFS 模块的必要条件。这种训练策略可确保模型在训练初期建立稳健的深度估计基础，随后逐步引入 AFS 模块进行精细化的样本选择和特征学习。

综上所述，本方法的损失函数设计和训练策略充分考量目标检测任务的需求与挑战，通过合理选择和组合损失函数并采用有效训练策略，保障了模型在 2D 与 3D 目标检测任务中的性能，不仅提升了检测精度，还增强了其在复杂场景下的鲁棒性与泛化能力。



第四章 实验

4.1 实验数据集与预处理

4.1.1 KITTI 数据集

在单目 3D 目标检测研究中,数据集的质量与特性对算法训练和评估效果至关重要。KITTI^[26]数据集因具备多传感器数据融合能力、详细标注信息和真实场景覆盖等显著优势成为首选。首先,其支持多传感器数据融合,提供了 RGB 图像、LiDAR 点云和雷达数据,这为开展多模态 3D 检测研究,提升算法的精度和鲁棒性,奠定了坚实的数据基础。其次,KITTI 数据集的标注信息十分详细,涵盖目标的 3D 位置、尺寸和方向等关键信息,能满足 3D 目标检测任务对精准监督信息的需求,提高模型对目标 3D 属性的识别能力。最后,数据采集自真实驾驶场景,包含多种天气和光照条件,使训练出的模型更适应实际自动驾驶中的复杂环境。

表 4.1 KITTI 数据标注信息

标注	含义
类别	目标物体的类别,如 Car、Pedestrian、Cyclist 等。
截断程度	目标物体在图像中的截断程度(0~1,0 表示未截断,1 表示完全截断)
遮挡程度	目标物体在图像中的遮挡程度(0=完全可见,1=部分遮挡,2=大部分遮挡,3=未知)
观察角度	目标物体相对于相机的水平视角,范围为 $-\pi$ 到 π 。
左上 x、左上 y	目标物体 2D 边界框的左上角坐标。
右下 x、右下 y	目标物体 2D 边界框的右下角坐标。
高、宽、长	目标物体的 3D 尺寸。
位置 x、位置 y、位置 z	目标物体在相机坐标系中的 3D 位置。
方向角	目标物体的 3D 方向角,范围为 $-\pi$ 到 π 。

KITTI 数据集主要包含车辆(Car)、行人(Pedestrian)和骑行者(Cyclist)三类目标,涵盖了自动驾驶场景中的主要交通参与者。标注文件采用文本格式,标注信息的格式如表 4.1 所示。每行对应一个目标,包括类别、截断程度、遮挡程度、观察角度、



2D 边界框、3D 尺寸、3D 位置及其方向角等信息。相机标定文件是单目 3D 检测的核心。其中相机内参矩阵 P2 内容如公式 4-1 所示，用于 3D 点到 2D 图像的投影，是 ROI-Align 特征提取与深度估计的基础。

$$P2 = \begin{pmatrix} f_x & 0 & c_x & 0 \\ 0 & f_y & c_y & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix} \quad (4-1)$$

式中， f_x, f_y 为焦距， c_x, c_y 为主点坐标（图像坐标系原点在成像平面的位置），修正旋转矩阵 $R0_rect$ 则用于校准相机光轴偏移，确保多视角几何一致性。

实验基于 KITTI 数据集展开，该数据集包含 7481 张训练图像和 7518 张测试图像。覆盖汽车、行人、骑自行车者三类目标，每类划分为简单、中等、困难三个难度级别。在实验中，将 7481 张训练图像分为训练集（3712）和验证集（3769）。分别用于模型训练与性能评估，其中 25% 的物体存在遮挡（遮挡程度大于等于一），12% 的 Car 类物体位于 50 米以外，对单目检测的特征选择与深度估计提出了较高要求。

4.1.2 数据预处理

数据预处理是单目 3D 目标检测实验的关键环节，旨在将原始数据转换为适合模型输入的标准化格式，并通过数据增强提升模型鲁棒性。预处理首先通过相机内参矩阵 P2 实现坐标系转换，利用公式 4-2 将相机坐标系下的 3D 点(X_c, Y_c, Z_c)投影至图像坐标系，建立 3D 空间与 2D 图像的几何映射关系，为后续特征提取提供坐标依据。

$$\begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = P2 \cdot \begin{pmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{pmatrix} \quad (4-2)$$

随后，通过 ROI-Align 操作从 2D 检测头输出的边界框($u_{min}, v_{min}, u_{max}, v_{max}$)中提取固定尺寸（7×7）的目标特征 F_{obj} ，实现标准化。

在数据清洗与标准化阶段，首先过滤 $Z_c < 0$ （违反成像物理规律）和尺寸异常的无效样本，确保训练数据的有效性样本；然后将图像尺寸统一调整为 1242×375 像素，并进行标准化处理。数据增强环节以 MixUp3D 为核心方法，通过随机混合比例 λ 取整如公式 4-3 所示。

$$\lambda \sim \text{Beta}(1.0, 1.0) \quad (4-3)$$

$$x_{mix} = \lambda \cdot x_a + (1 - \lambda) \cdot x_b \quad (4-4)$$

将同焦距图像中的目标（如车辆与行人）按公式 4-4 所示方法叠加，生成混合图像，同时保留原标注。这种增强策略模拟了真实场景中“投影重叠但物理坐标不冲突”的遮挡现象，提升模型对遮挡目标的特征判别能力；同时辅以随机水平翻转模拟左右视角变化和光度扰动，增强模型对光照变化的鲁棒性。值得注意的是，没有采用随机旋转方法，避免破坏相机坐标系下的投影关系。

评估与训练配置紧密关联预处理效果：采用 KITTI 官方的 AP3D（3D 检测平均精度，IoU=0.7）与 APBEV（鸟瞰图平均精度，IoU=0.7）指标，在召回率阈值 R=40 条件下以中等难度（Moderate）样本为主要评估基准，确保结果与领域内主流方法可比。训练使用 Adam 优化器（初始学习率 1×10^{-3} ），前 5 个训练轮次采用线性 warm-up 策略（学习率从 0 逐步提升至初始值），缓解模型初期训练不稳定问题。模型训练 600 个轮次，通过较长的训练周期充分学习增强数据的特征分布，提升模型泛化能力。

4.2 可视化结果与分析

本小节展示 MonoSelect3D 模型在 KITTI 数据集上的 3D 检测可视化结果，通过红色预测 3D 框与绿色真实标注的对比，直观呈现模型在不同场景下的检测能力。如图 4.1 与图 4.2 所示，模型对近距至中距目标展现出较强的空间定位能力：预测 3D 框与真实框在目标上基本吻合，清晰还原了目标的三维尺寸，表明模型有效学习了目标的几何特征与图像空间映射关系。近中距场景中，模型对目标边界的刻画细腻，尤其在车辆侧面轮廓预测中，体现出对细节特征的敏感捕捉能力。




图 4.1 近、中距目标检测



图 4.2 中、远距目标检测

在远距离场景（图 4.2 中远处车辆），受限于单目视觉的深度估计不确定性及图像分辨率降低，部分目标出现漏检或预测框偏移现象。模型对极远目标的深度感知存在模糊性，反映了单目 3D 检测在缺乏视差线索时的固有挑战。不过，模型仍能通过几何先验约束（如车辆尺寸比例）维持预测框的尺度，避免出现明显违背物理规律的估计结果。

针对遮挡场景如图 4.3 所示，模型表现出显著的鲁棒性优势。当目标因前车遮挡导致视觉信息缺失时，MonoSelect3D 通过 AFS 模块动态过滤遮挡区域的背景噪声，聚焦于目标可见部分的特征（如未遮挡的车轮、车身边缘），并结合 SpatialMixup 数据增强学习到的遮挡模式先验，实现对缺失几何信息的推理补全。可视化结果显示，模型能够基于局部可见特征生成完整 3D 边界框，预测框与真实框的空间位置与朝向保持一致，验证了自适应特征选择与上下文语义推理的有效性。



图 4.3 对被遮挡目标物体的识别

综上，MonoSelect3D 在近中距及遮挡场景中展现出对目标 3D 结构的精准建模能力，其核心优势在于通过动态特征选择与几何先验约束，有效应对单目视觉的固有挑战。可视化结果清晰呈现了模型对不同距离、遮挡程度目标的处理逻辑，为算法的实际应用提供了直观的性能参考。



4.3 实验结果与分析

本小节在 KITTI 测试集上对 Car 类目标的检测性能进行了系统评估，为便于理解实验结果，首先明确核心指标：2D 边界框（BBox）检测精度基于图像平面预测框与真实框的交并比（IoU）计算，即预测框与真实框的交集面积占并集面积的比例，衡量二维空间定位能力；鸟瞰图（BEV）检测精度在顶视投影平面计算 IoU，反映水平面上位置与尺度估计能力；3D 目标框检测精度在三维空间计算 IoU，综合评估深度、尺寸及方位的整体预测质量；平均方向相似度（AOS）通过计算预测方向角与真实值的余弦相似度均值量化方向估计的准确性，其计算方式如公式 4-5 所示。

$$AOS = \frac{1}{N} \sum_{i=1}^N \cos(\theta_{\text{pred},i} - \theta_{\text{gt},i}) \quad (4-5)$$

式中， θ_{pred} 为预测方向角， θ_{gt} 为真实方向角，值越接近 1，方向预测越可靠。

实验涵盖这些指标在不同 IoU 阈值（0.3/0.5/0.7）及目标难度（Easy/Moderate/Hard，按遮挡程度、尺寸及距离划分，Easy 为无遮挡、大尺寸、近距目标，Hard 为重度遮挡、小尺寸、远距目标）下的表现，具体结果如表 4.2 所示。

表 4.2 Car 类目标检测性能

指标	IoU 阈值	Easy (%)	Moderate (%)	Hard (%)
BBox	0.70	98.70	95.04	87.76
BEV	0.70	34.18	25.20	22.72
3D	0.70	26.02	19.37	16.44
AOS	0.70	98.23	94.02	85.97
BEV	0.50	69.37	53.93	49.11
3D	0.50	63.28	48.78	44.14
BEV	0.30	87.27	72.74	67.65
3D	0.30	84.45	70.08	65.00

从表中可见，在 IoU 阈值为 0.7 时，BBox 检测精度在 Easy/Moderate/Hard 难度下分别达到 98.70%、95.04%和 87.76%，表现出对目标 2D 定位的强鲁棒性。相比之下，模型在 3D 检测中的性能出现显著差异，3D 检测任务面临更大挑战，3D@0.7 指标在相同难度下分别为 26.02%、19.37%和 16.44%，揭示深度估计误差累积及遮挡场景几何特征



退化导致的精度衰减。

方向估计能力通过 AOS 指标衡量，在 $\text{IoU}=0.7$ 时，Easy/Moderate/Hard 难度下的数值分别为 98.23%、94.02% 和 85.97%。这主要得益于多区间方向预测策略有效降低了量化误差，表明目标方向预测具有较高的可靠性，并非 3D 检测性能的主要瓶颈。BEV 检测性能在 $\text{IoU}=0.7$ 时的 Moderate 难度下为 25.20%，显著优于 3D 检测的 19.37%，但仍低于 2D 检测的 95.04%，这说明鸟瞰图视角通过忽略高度维度有效缓解了投影歧义，但仍需要通过精细的空间几何建模来进一步提升 3D 定位精度。

在低 IoU 阈值的场景中，模型的实用性显著提升。当 IoU 阈值放宽至 0.5 时，3D 检测精度在 Moderate 难度下提升至 48.78%，而当 IoU 进一步放宽至 0.3 时，检测精度达到 70.08%，这表明模型在粗略定位任务中具备较高的可靠性，但在如自动驾驶等高精度工业场景中，其检测能力仍有待进一步优化。值得注意的是，模型在 EPOCH_600 时的 Hard 难度 $3\text{D}@0.7$ 指标（16.44%）与训练集结果未见显著偏差，且 $\text{BEV}@0.3$ 指标保持稳定（67.65%），这充分验证了 AFS 模块的动态特征选择机制与 SpatialMixup 数据增强策略在抑制过拟合、增强长尾分布适应性方面的有效性。

当前模型在高 IoU 阈值下的 3D 定位精度仍存在明显瓶颈，在 Hard 难度下 $3\text{D}@0.7$ 指标（16.44%）与 BBox 检测精度（87.76%）之间的差距显著，这一差距主要源于三方面因素：一是远距离目标的深度估计误差会随距离呈非线性累积放大；二是重度遮挡场景下局部特征退化，导致 3D 几何推理失效；三是现有损失函数对 3D 边界框交并比的几何敏感性建模不足。未来可从多模态特征深度融合（如引入激光雷达辅助深度修正）、设计遮挡感知的注意力机制（聚焦可见区域特征）以及引入几何驱动的损失函数（如可微分 3DGIoU ）这三个方向展开优化，以提升复杂场景下高精度检测的鲁棒性。

4.4 消融实验

本节通过系统性消融实验验证各模块的贡献，所有实验在 KITTI 验证集 Car 类别上进行，训练周期固定为 150，结果取五次随机种子实验的中位数以消除随机性波动。实验遵循控制变量原则，基础配置包含 2D 检测主干与 3D 回归头，逐步引入关键组件以量化其影响。消融实验结果如表 4.3 所示。



表 4.3 在 KITTI 验证集上进行的消融实验结果（Car 类别）

D	S	θ	W	M	Easy	Mod.	Hard
					AP_{3D}/AP_{BEV}	AP_{3D}/AP_{BEV}	AP_{3D}/AP_{BEV}
✓	-	-	-	-	21.72/30.74	15.63/22.74	12.80/19.14
✓	✓	-	-	-	17.03/24.40	12.77/18.73	11.08/15.84
✓	✓	✓	-	-	24.78/33.32	17.65/23.92	14.53/20.21
✓	✓	✓	✓	-	24.63/33.63	17.55/25.03	14.62/21.48
✓	✓	✓	✓	✓	25.52/33.30	19.38/25.50	16.74/23.16
✓	✓	✓	✓	✓	33.51/42.85	24.41/32.14	21.95/28.15
✓	✓	✓	✓	✓	33.46/43.00	24.77/32.90	21.66/29.09

首先，自适应样本选择机制（AFS）显著提升了 3D 检测精度。如表 4.3 第 1-4 行所示，D、S、 θ 分别表示 AFS 模块作用于深度、尺寸和方向角。W 表示采用 warm-up 策略，M 表示使用 SpatialMixup 方法。当 AFS 模块仅作用于深度回归时， $AP_{3D}@0.7$ 在 Easy/Moderate/Hard 难度下分别提升 4.73%、3.82% 与 3.14%。这与单目检测的特性相关：深度估计缺乏几何先验导致误差非线性累积，AFS 通过动态筛选高置信度区域特征抑制噪声干扰，使深度预测 MAE 降低 18.3%。近距离目标（<20m）场景中 MAE 降低 23.5%，但远距离目标（>50m）受像素分辨率限制仅降低 10.2%。基于此，后续消融实验中 AFS 模块仅作用于深度属性。

其次，渐进式训练策略的必要性显著。如表 4.3 第 2 行所示，无预热策略时 AFS 随机采样可能丢弃正样本、保留负样本，导致 Easy 难度 AP_{3D} 从 21.72% 降至 17.03%。过早激活样本选择会错误过滤有效特征，迫使网络在低质量梯度下收敛。通过延迟启动策略（前 30% 周期禁用 AFS），模型能够建立稳健的深度回归基础，Hard 难度下训练损失方差从 0.54 降至 0.18，收敛稳定性提升 67%。

动态采样策略的优越性通过对比实验得到验证。如表 4.3 所示，AFS 在 AP_{3D} 指标上较固定位置采样（如 7×7 网格）提升 23.6%，较基于深度图或分割图的启发式采样提升 7.4%。这种优势归因于 AFS 的空间自适应性——通过端到端学习特征置信度，避免人工设计规则的主观偏差。同时，AFS 在计算效率上表现优异，动态采样耗时仅增加 1.2ms，显著低于分割图采样的 9.7ms 开销，为实时检测提供了可行性支持。



此外，AFS 与 SpatialMixup 的协同效应展现出非线性增益特征。如表 4.4 所示，独立使用 AFS 与 SpatialMixup 分别带来+3.06 与+3.80 的 AP_{3D} 提升，而联合使用时增益扩大至+11.74，显著超过两者简单相加的理论值（+6.86）。这种协同性源于两方面机制：其一，SpatialMixup 通过物理约束的混合样本扩展特征多样性，而 AFS 强化模型对关键特征的聚焦能力；其二，SpatialMixup 缓解了 AFS 在长尾分布下的过拟合风险，而 AFS 通过动态加权提升混合样本的利用率。

表 4.4 不同样本选择方法在 KITTI 验证集上的性能对比（Car 类别）

Method	Easy	Moderate	Hard
	AP_{3D}/AP_{BEV}	AP_{3D}/AP_{BEV}	AP_{3D}/AP_{BEV}
1×1	18.14/25.54	12.68/18.68	10.36/15.66
3×3	20.06/28.30	15.28/21.95	12.92/19.00
5×5	20.75/30.23	15.14/22.39	13.02/18.93
7×7	21.72/30.74	15.63/22.74	12.80/19.14
Depth	23.85/31.36	15.92/21.17	11.64/16.76
Seg	24.11/31.82	15.82/21.51	13.09/16.90
AFS	24.78/33.32	17.65/23.92	14.53/20.21

综上，实验结果表明：预热策略通过稳定初始化优化模型收敛性；AFS 与 SpatialMixup 的协同效应为性能提升提供关键驱动力；动态采样策略在精度与效率间实现了最佳平衡。

4.5 结论

本文针对单目 3D 检测中 3D 属性学习的样本选择难题，采用了自适应特征选择模块（AFS）和无歧义数据增强方法（SpatialMixup）。AFS 模块通过动态权重机制为每个目标自适应分配正样本特征，解决了传统方法中固定样本选择导致的特征歧义问题；SpatialMixup 则通过引入物理约束的 3D 空间混合策略，生成多样化的遮挡和截断样本，显著提升了模型对复杂场景的泛化能力。

在 KITTI 数据集上的实验结果表明，MonoSelect3D 在 Car 类别检测性能优异，尤其在中等遮挡和中距场景。验证了模型对遮挡目标的推理能力和远距离目标的检测局限性。未来研究可结合多模态融合或时序信息，提升单目 3D 检测在极端场景下的性能。



第五章 总结与展望

5.1 结论

本论文使用了一种基于 MonoSelect3D 的单目 3D 目标检测方法，旨在提高单目 3D 目标检测的精度和鲁棒性。通过引入自适应的样本选择(AFS)模块和物理约束 MixUp3D 数据增强方法，本方法在 KITTI 数据集上取得了显著的性能提升。以下是本文的主要内容：

（1）自适应样本选择（AFS）模块：采用 AFS 模块，通过 Gumbel-Softmax 技巧和相对距离样本划分策略，从目标物体的特征图中自适应地选择最适合用于 3D 属性学习样本。这种自适应的样本选择机制能够有效过滤掉不相关或具有误导性的特征，使模型能够专注于对 3D 检测真正有价值的特征，从而提高了模型对目标 3D 特性的理解能力。

（2）MixUp3D 数据增强方法：采用一种基于物理约束的数据增强方法 MixUp3D，通过模拟物理世界中的空间重叠现象来扩充训练数据。MixUp3D 方法能够在保持成像原理一致性的前提下，生成具有空间重叠的图像样本，从而丰富训练数据的多样性，提升模型对 3D 属性的感知能力。

（3）实验验证：通过对模型进行评估，得到 MonoSelect3D 方法在 Car 类别中取得了很好的性能。实验结果表明，与现有的单目 3D 检测方法相比，MonoSelect3D 在保持较高检测精度的同时，大幅降低了对昂贵 LiDAR 传感器的依赖，具有较高的实用价值。

5.2 展望

未来的研究将致力于进一步提升单目 3D 目标检测的性能和实用性。一方面，将探索多传感器数据融合技术，结合 LiDAR 点云、雷达数据等多源信息，以增强模型对复杂场景的感知能力。另一方面，将致力于开发更轻量化的网络结构和模型压缩技术，以满足嵌入式设备的实时性需求。此外，还将拓展数据增强技术，模拟更多真实场景下的物理现象，进一步提升模型的鲁棒性和适应性。同时，提高模型的可解释性也是未来的一个重要方向，通过可视化中间特征和引入注意力机制，帮助研究人员更好地理解模型的决策过程。最后，探索无监督和自监督学习方法，以减少对标注数据的依赖，降低数据标注成本，将为单目 3D 目标检测技术的广泛应用开辟新的道路。希望这些研究方向能够推动单目 3D 目标检测技术的持续进步，为自动驾驶技术的发展贡献力量。



参考文献

- [1] 胡越, 罗东阳, 花奎, 等.关于深度学习的综述与讨论[J].智能系统学报, 2019,14(1):1-19.
- [2] 董本志, 于尚书, 景维鹏.多先验融合的图像显著性目标检测算法[J].计算机工程与应用, 2019,55(2):179-186.
- [3] Chen X,Kundu K,Zhang Z,etal.Monocular 3D object detection for autonomous driving[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2016:2147-2156.
- [4] Chen X,Kundu K,Zhu Y,etal.3D object proposals using stereo imagery for accurate object class detection[J].IEEE Transactions on Pattern Analysis and Machine Intelligence,2017,40(5):1259-1272.
- [5] Mousavian A,Anguelov D,Flynn J,etal.3D bounding box estimation using deep learning and geometry[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2017:7074-7082.
- [6] Xu B,Chen Z.Multi-level fusion based 3D object detection from monocular images[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2018:2345-2353.
- [7] Qin Z,Wang J,Lu Y.Monogrnet:A geometric reasoning network for monocular 3D object localization[J].arXiv:1811.10247,2018.
- [8] Manhardt F,Kehl W,Gaidon A.Roi-10D:Monocular lifting of 2D detection to 6D pose and metric shape[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2019:2069-2078.
- [9] Liu L,Ouyang W L,Wang X G,etal.Deep learning for generic object detection:A survey[J].arXiv:1809.02165,2018.
- [10] Chabot F,Chaouch M,Rabarisoa J,etal.Deep manta:A coarse-to-fine many-task network for joint 2D and 3D vehicle analysis from monocular image[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2017:2040-2049.
- [11] He T,Soatto S.Mono3D++:Monocular 3D vehicle detection with two-scale 3D hypotheses and task priors[J].arXiv:1901.03446,2019.
- [12] Shah S A A,Bennamoun M,Boussaid F.Keypoints-based surface representation for 3D modeling and 3D object recognition[J].Pattern Recognition,2017,64:29-38.
- [13] Simonelli A,BulòS R,Porzi L,etal.Disentangling monocular 3D object detection[J].arXiv:1905.12365,2019.
- [14] GIRSHICK R, DONAHUE J, DARRELL T, etal.Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 580-587
- [15] GIRSHICK R.Fast R-CNN[C]//IEEE International Conference on Computer Vision, 2016.
- [16] REN S, HE K, GIRSHICK R, etal.Faster R-CNN: towards real-time object detection with region proposal networks[J].IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39 (6): 1137-1149.
- [17] REDMON J, DIVVALA S, GIRSHICK R, etal.You only look once: unified, real-time object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 779-788.
- [18] LIU W, ANGUELOV D, ERHAN D, etal.SSD: single shot multibox detector[C]//European Conference on Computer Vision.Cham: Springer, 2016: 21-37.
- [19] Xingyi Zhou, Dequan Wang, and Philipp Krahenbuhl. Objects as points. In arXiv preprint



- arXiv:1904.07850, 2019. 1, 2, 4, 5
- [20] Fisher Yu, Dequan Wang, Evan Shelhamer, and Trevor Darrell. Deep layer aggregation. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018. 4
- [21] Yan Lu, Xinzhu Ma, Lei Yang, Tianzhu Zhang, Yating Liu, Qi Chu, Junjie Yan, and Wanli Ouyang. Geometry uncertainty projection network for monocular 3d object detection. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pages 3111 – 3121, 2021. 2, 3, 4, 5, 6, 7
- [22] Emil Julius Gumbel. Statistical theory of extreme values and some practical applications: a series of lectures. US Government Printing Office, 1954. 4
- [23] Eric Jang, Shixiang Gu, and Ben Poole. Categorical reparametrization with gumble-softmax. In International Conference on Learning Representations (ICLR 2017). OpenReview. net, 2017. 2, 4, 5
- [24] Wouter Kool, Herke Van Hoof, and Max Welling. Stochastic beams and where to find them: The gumbel-top-k trick for sampling sequences without replacement. In International Conference on Machine Learning, pages 3499–3508. PMLR, 2019. 2, 4
- [25] Yan Lu, Xinzhu Ma, Lei Yang, Tianzhu Zhang, Yating Liu, Qi Chu, Junjie Yan, and Wanli Ouyang. Geometry uncertainty projection network for monocular 3d object detection. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pages 3111 – 3121, 2021. 2, 3, 4, 5, 6, 7
- [26] Geiger A, Lenz P, Urtasun R. Are we ready for autonomous driving? the Kitti vision benchmark suite[C]//Proceedings of 2012 IEEE Conference on Computer Vision and Pattern Recognition, 2012:3354-3361



致谢

时光荏苒，如白驹过隙，四年的大学生活即将画上句号，而我也即将完成我的本科毕业设计。回首这段岁月，有太多的人和事值得我感恩与铭记。

首先，我要衷心感谢我的导师。在毕业设计的过程中，您给予了我无数宝贵的指导和建议。从选题的方向到每一个细节的打磨，从遇到难题时的耐心解答到论文撰写的反复修改，您的严谨治学态度和无私奉献精神深深地感染了我，成为我不断前进的动力。您的每一次悉心指导，都为我拨开了迷雾，让我在学术的道路上少走了许多弯路。

此外，我还要向我的家人表达我深深的感激。感谢你们一直以来对我的默默支持和付出，无论是在我顺利时给予的鼓励，还是在我遇到困难时给予的安慰，都是我不断前行的坚强后盾。你们的理解和支持让我能够心无旁骛地追求自己的学业梦想。

在未来，我将带着在这所大学收获的知识和成长，继续追逐自己的梦想。我深知，前方的道路不会一帆风顺，但我相信，凭借在这里培养的坚韧和勇气，我一定能够克服困难，迎接新的挑战。

人生从此将展开新的一页。但前途必然是光明的！